

Maestría en Ciencia de Datos

Departamento de Matemática y Ciencias

Machine Learning para analizar el rendimiento escolar en Argentina: resultados de las evaluaciones Aprender 2023

Lucía Pezzarini

2026

Directora: Marcela Svarc

Codirectora: María Victoria Anauati



Resumen

Este trabajo utiliza técnicas de *machine learning* para analizar los determinantes del desempeño de las escuelas argentinas en la Evaluación Nacional Aprender 2023. A partir de los cuestionarios de estudiantes, docentes y directivos, se construye una base con más de 120 predictores. Luego, se entrenan modelos basados en conjuntos de árboles de decisión, en particular los algoritmos *Random Forest* y *XGBoost*, para predecir el porcentaje de alumnos por escuela que alcanzan niveles satisfactorios o avanzados en Lengua y Matemática.

La interpretación de los modelos entrenados se realiza mediante el cálculo de los valores *Shap*, que permite identificar la contribución específica de cada variable a la predicción del modelo. Asimismo, esta herramienta posibilita la agregación de variables en categorías analíticas. En este trabajo las variables se agrupan en cinco categorías: factores del hogar, factores individuales, factores asociados a la trayectoria escolar, factores institucionales y factores de contexto. A su vez, los valores *Shap* permiten analizar el impacto de las variables tanto a nivel global (conjunto completo de escuelas) como a nivel individual y de grupos de escuelas, así como también realizar comparaciones entre ellos.

Los resultados confirman la centralidad del nivel socioeconómico y sus variables asociadas, pero también destacan la importancia de la asistencia temprana al jardín, la repitencia, el tiempo de viaje a la escuela, ciertos patrones de uso de redes sociales, el clima escolar, la duración de la jornada escolar, la antigüedad de los directores, entre otras. El trabajo muestra así el potencial de combinar técnicas de *machine learning* e interpretabilidad para generar evidencia útil en el diseño de políticas educativas basadas en datos.

Índice general

1	Introducción	1
2	Datos	3
2.1.	Procesamiento de los datos	3
2.2.	Análisis descriptivo de los datos	5
3	Metodología	12
4	Resultados	14
4.1.	Modelos entrenados	14
4.2.	Interpretación de los resultados a partir del uso de los valores <i>Shap</i>	15
4.2.1.	Introducción teórica a los valores <i>Shap</i>	16
4.2.2.	Resultados globales	17
4.2.3.	Relación entre la distribución de las variables y los valores <i>Shap</i>	21
4.2.4.	Diferencias en el desempeño entre las escuelas de NSE bajo	33
5	Reflexiones finales	42
6	Anexo de tablas y gráficos	45
	Bibliografía	47

CAPÍTULO 1

Introducción

En Argentina, la Evaluación Nacional Aprender es el dispositivo nacional que evalúa anualmente el aprendizaje de los estudiantes. En 2023, se llevó a cabo un operativo censal en el que participaron estudiantes de sexto grado de la educación primaria en las áreas de Lengua y Matemática. Los resultados de las pruebas se publican junto con cuestionarios a estudiantes, docentes y directores, que permiten caracterizar múltiples dimensiones vinculadas al aprendizaje: condiciones materiales de los hogares, trayectorias escolares, características individuales de los estudiantes, factores institucionales, entre otros. A pesar de la gran cantidad de información que ofrecen los cuestionarios de Aprender, en la práctica suele explorarse solo una parte acotada de ese universo, dejando fuera otras dimensiones potencialmente relevantes, limitando el aprovechamiento pleno de la diversidad de información relevada.

En los últimos años, los modelos de aprendizaje automático o *machine learning* se han consolidado como un enfoque relevante para analizar el desempeño educativo (Chen et al., 2025 [4]; Albreiki et al., 2021 [1]; Sekeroglu et al., 2021 [24]). En particular, los modelos basados en árboles de decisión, como *Random Forest* o *XGBoost*, se destacan por su capacidad para trabajar con un gran número de predictores, capturar interacciones complejas y modelar relaciones no lineales, mostrando un buen desempeño para predecir resultados en pruebas estandarizadas. Sin embargo, su principal ventaja, la capacidad predictiva, suele venir acompañada de una menor transparencia a la hora de interpretar los resultados o explicar el funcionamiento de los modelos. Esto, a su vez, resulta una dificultad a la hora de responder a preguntas centrales para las políticas educativas: ¿Qué factores están detrás de las predicciones del modelo?, ¿En qué medida contribuye cada uno de estos factores al desempeño observado?

Para responder a estas preguntas, trabajos recientes utilizan los valores *Shap* (SHapley Additive exPlanations) como herramienta para explicar los resultados de los modelos predictivos (ver por ejemplo Liu et al., 2022 [15]; Huang et al., 2024[12]). Se trata de una herramienta mediante la cual es posible descomponer la predicción a nivel de cada observación individual en contribuciones aditivas atribuibles a cada variable.

Este trabajo se inscribe en esa línea y tiene como objetivo general predecir el desempeño promedio de las escuelas argentinas en las Aprender 2023 e identificar los principales determinantes asociados a esos resultados. La variable que se busca predecir se define como el porcentaje de alumnos por escuela que alcanzan simultáneamente un desempeño satisfactorio o avanzado en Lengua y Matemática. A partir de los microdatos de Aprender, se construye una base a nivel escuela que integra información proveniente de los tres cuestionarios (estudiantes, docentes y directivos), dando lugar a una base final de más de 120 variables potencialmente explicativas del rendimiento escolar.

El trabajo se organiza alrededor de las siguientes preguntas orientadoras:

1. ¿Hasta qué punto los modelos de *machine learning* basados en árboles logran producir predicciones precisas del rendimiento de las escuelas en las pruebas Aprender?
2. Entre el conjunto de variables contempladas en los modelos, ¿cuáles son las que más contribuyen a explicar el desempeño promedio de las escuelas? ¿Cómo se distribuyen esas

contribuciones entre cinco grandes grupos de factores: del hogar, individuales, de trayectoria escolar, institucionales y de contexto? Aquí se analiza si las relaciones entre predictores y desempeño educativo son lineales, presentan umbrales o puntos de inflexión, así como en qué medida el NSE condiciona la forma y la magnitud de esos efectos.

3. Dentro del conjunto de escuelas de NSE bajo, ¿qué factores o variables distinguen a aquellas que logran buenos resultados (escuelas más resilientes) de otras que, en contextos similares, obtienen un rendimiento menor? El objetivo es identificar patrones para comprender cómo ciertas instituciones logran mitigar, al menos parcialmente, las desventajas socioeconómicas.

Para responder estas preguntas se entrenan modelos de *Random Forest* y *XGBoost* sobre el conjunto de escuelas urbanas con al menos cinco estudiantes que hubieran realizado ambas evaluaciones. La comparación entre modelos se realiza a partir de dos métricas de evaluación estándar, el error absoluto medio (MAE) y la raíz del error cuadrático medio (RMSE). Se selecciona al modelo *XGBoost* como el modelo con mejor desempeño predictivo y capacidad de generalización de resultados. Luego, los resultados de este modelo se interpretan mediante valores *Shap*, ordenando a los predictores según su importancia global y analizando de qué manera cada variable contribuye a la predicción de cada escuela o grupo de escuelas. Las variables se agrupan en las cinco categorías: factores del hogar, factores individuales, trayectoria escolar, factores institucionales y factores de contexto.

Un aporte central de este trabajo es mostrar cómo la combinación de modelos de *machine learning* y métodos de interpretación como los valores *Shap* permite aprovechar la amplitud de información disponible en Aprender 2023 sin restringirse a un conjunto reducido de predictores. Desde esta perspectiva metodológica, se evidencia que es posible integrar un gran número de variables y obtener resultados interpretables que dialoguen con la literatura educativa.

En términos empíricos, los hallazgos corroboran la importancia del nivel socioeconómico y de las condiciones del hogar como determinantes del rendimiento escolar, pero también destacan otros factores. Entre ellos se encuentran los vinculados a la trayectoria escolar, como la repitencia o la asistencia temprana al jardín, a características individuales, incluyendo ciertas responsabilidades o actividades de colaboración en el hogar o patrones de uso de redes sociales, así como también, elementos institucionales, como la estabilidad de los equipos directivos o la carga horaria docente en la escuela. Por último, también se observan diferencias relevantes entre provincias y sectores de gestión.

El resto del trabajo se estructura de la siguiente manera. En el Capítulo 2 se describen los datos y el proceso de limpieza y construcción de la base a nivel escuela. En el Capítulo 3 se presenta la metodología, incluyendo los modelos de árboles de decisión, los procedimientos de entrenamiento y selección de hiperparámetros y el marco teórico de los valores *Shap*. En el Capítulo 4 se exponen los resultados. En primer lugar, se compara la capacidad predictiva de los modelos entrenados. Luego, la sección dedicada a la interpretación de los resultados se divide en tres. Por un lado, se analizan los valores *Shap* globales y la relevancia relativa de cada categoría de factores en el conjunto total de las escuelas. En este análisis, se destaca la consistencia entre las variables identificadas como relevantes por los modelos y aquellas señaladas por la literatura previa sobre desempeño educativo. Más adelante, se explora la relación entre la distribución de las variables y sus efectos estimados a partir de los valores *Shap*. Finalmente, se analizan las diferencias entre escuelas de bajo NSE con alto y bajo desempeño. El trabajo concluye con una discusión de los principales hallazgos, las limitaciones y posibles líneas de investigación futura.

CAPÍTULO 2

Datos

Los datos de este trabajo provienen de la Evaluación Nacional Aprender realizada en septiembre de 2023 a estudiantes de sexto año de la escuela primaria¹. La base original de microdatos cuenta con el registro de 19.834 escuelas y de 641.981 estudiantes, tanto del sector estatal como privado y del ámbito rural y urbano (Ministerio de Capital Humano, 2023 [18]).

El relevamiento incluye el resultado de la evaluación en las áreas de Lengua y Matemática, así como también cuestionarios complementarios a estudiantes, docentes y directivos, que en conjunto suman más de 600 preguntas.

2.1. Procesamiento de los datos

En el procesamiento de datos se contemplan los siguientes pasos: 1. La definición de las escuelas a incluir; 2. La definición de las variables a incluir (preguntas de los cuestionarios); 3. La transformación de las respuestas individuales de los cuestionarios en indicadores agregados a nivel de escuela.

En cuanto a las escuelas a considerar, se incluyen únicamente las escuelas urbanas con al menos cinco estudiantes que hubieran realizado ambas evaluaciones, de forma tal de garantizar la comparabilidad entre ellas. Esta estrategia es consistente con la con la que siguen otros trabajos recientes que analizan las evaluaciones Aprender (Tommasi et al., 2025 [26]).

De este modo, de las 19.834 escuelas de la base inicial, el universo se redujo a 12.007 correspondientes al ámbito urbano. A su vez, al restringir el análisis a aquellas escuelas con cinco o más estudiantes con respuestas en ambas evaluaciones, la base final quedó conformada por 11.357 escuelas (el 94,6 % del total de escuelas urbanas).

En las pruebas Aprender se reporta tanto un puntaje individual por alumno como una categorización en cuatro niveles: por debajo del básico, básico, satisfactorio y avanzado. En este trabajo, se define a la variable dependiente como el promedio de estudiantes por escuela que alcanzaron un desempeño satisfactorio o avanzado en ambas áreas de evaluación, Lengua y Matemática.^{2 3}

Con relación a las características que se utilizan para predecir el desempeño de las escuelas, se parte del universo de 668 variables presentes en los tres cuestionarios.⁴ El primer paso fue seleccionar, por relevancia analítica, un total de doscientas dos variables (202): tres (3) relacionadas a características de la escuela —sector de gestión, región y jurisdicción— ciento veintitrés (123) del cuestionario de estudiantes, cuarenta y seis (46) del de directivos y treinta (30) del de docentes. En esta etapa se excluyen las variables *NSE_puntaje* y *NSE_nivel* y en su lugar se utilizan las variables que las componen. Las variables *NSE_puntaje* y *NSE_nivel* hacen referencia a un índice construido por

¹En adelante, Aprender 2023

²Para obtener este promedio, primero se creó una variable *dummy* a nivel estudiante, que toma el valor uno si el alumno obtuvo en ambas materias un resultado satisfactorio o avanzado. Luego, para cada escuela, se calculó el total de estudiantes con respuestas válidas en ambas materias. Finalmente, se calculó la proporción de estudiantes con nivel satisfactorio o avanzado

³Cuando se habla de buen desempeño, se hace referencia a los estudiantes que alcanzaron los niveles satisfactorio o avanzado en ambas materias.

⁴Aquí las variables hacen referencia a las preguntas de los tres cuestionarios.

2. Datos

la Secretaría de Educación del Ministerio de Capital Humano a partir de las siguientes variables: nivel educativo de los padres, hacinamiento en el hogar —medido como personas por habitación— y la tenencia de ciertos bienes y servicios, entre los que se encuentran: baño con ducha o bañera, Heladera con freezer, Lavarropas, Conexión a Internet, Televisión por cable o digital, Canilla con agua apta para consumo humano, Auto, plataformas de streaming como Netflix, Amazon y Disney+, Computadora, Consola de videojuegos y Tablet. Además, hay variables que no conforman el índice pero están asociadas al nivel socioeconómico, como sector de gestión, libros en el hogar (Secretaría de Educación de la Nación, 2023 [23]).

Seguidamente, se calcula el porcentaje de respuestas faltantes por pregunta⁵ y se descartan aquellas contestadas por menos del 70 % de los estudiantes. Este umbral es más restrictivo que el utilizado en trabajos similares, como por ejemplo el de Huang, Zhou, Chen y Wu (2023) [12], quienes conservan variables con al menos el 30 % de respuestas (es decir, admiten hasta un 70 % de valores faltantes)⁶. En este paso se descartan 62 variables.⁷

Luego, se abordan duplicidades de contenido entre las preguntas. Por ejemplo, la pregunta sobre si el alumno vive con la madre o el padre, aparece dos veces en el cuestionario. Las preguntas sobre el máximo nivel educativo alcanzado por los padres, aparecen tres veces. En estos casos, se seleccionaron las opciones con menor porcentaje de respuestas faltantes.⁸

Posteriormente, se efectúa una depuración por falta de consistencia entre las respuestas y fuentes de información externa. Las preguntas sobre pertenencia/ascendencia indígena y afrodescendencia presentaron tasas de respuesta afirmativa superiores al 20 %, contrastando con los datos del Censo 2022 (INDEC, 2025 [6]).^{9 10}

El siguiente paso consiste en la generación de nuevas variables. Se construye la variable personas por habitación, que tiene por función indicar el grado de hacinamiento presente en el hogar, y se define como el cociente entre la cantidad de integrantes del hogar y el número de habitaciones¹¹. Asimismo, la variable de sobriedad se codifica en dos diferentes dummies: (i) sobriedad = 1 para estudiantes con 1, 2 o 3 años de sobriedad (0 en caso contrario) y (ii) menos_edad = 1 para estudiantes menores de 11 años (0 en el resto de los casos). La lista final de variables a utilizar consiste en 126 variables¹².

⁵Las respuestas que se toman como faltantes son las que poseen valores Blanco (-9), (-8) y multimarca (-6).

⁶La elección de un umbral más exigente responde al mayor nivel de agregación utilizado en este trabajo. Mientras que Huang, Zhou, Chen y Wu (2023) realizan su análisis a nivel individual —lo que implica un tamaño muestral considerablemente mayor—, aquí las variables se construyen a nivel escuela, a partir del promedio de respuestas de los estudiantes. En este contexto, permitir un 70 % de valores faltantes implica, para grados de 30 estudiantes —la tercera parte de los colegios de la muestra— basar las variables en apenas diez respuestas por grado, lo cual podría no ser representativo. Desde un punto de vista analítico, la aplicación de un umbral más estricto no implica una pérdida significativa de información, dado que las variables que se consideran más relevantes para el análisis superan este umbral.

⁷Entre las variables que se conservan en este punto, diez de ellas contemplan valores faltantes entre 20 % y 25 %, y corresponden a los bloques de preguntas referidas a actividades que realiza durante el tiempo libre, sobre si la semana anterior realizó cierto tipo de actividades (como cultivar, cosechar, buscar leña o trabajar para una persona no familiar) y finalmente, opinión sobre resolución de problemas de geometría. Para el resto de las variables, la cantidad de valores faltantes es menor.

⁸En general, cuando las preguntas están contempladas más de una vez, solo una de las opciones tiene bajo porcentaje de valores faltantes (menor al 10 %), mientras que las alternativas tienen más del 50 % de los valores faltantes.

⁹ap18a y ap18c corresponden a “¿Tu/s mamá/s, papá/s o persona/s adulta/s responsable/s son de un pueblo indígena u originario o descendientes de una familia indígena u originaria? Mamá o adulta responsable” ap18b y ap18d a “¿Tu/s mamá/s, papá/s o persona/s adulta/s responsable/s son de un pueblo indígena u originario o descendientes de una familia indígena u originaria? Papá o adulto responsable”. No obstante, ap18b y ap18d fueron descartadas en pasos anteriores porque tenían un porcentaje de missings mayor al 75 %.

¹⁰ap19a y ap19c corresponden a “¿Tu/s mamá/s, papá/s o persona/s adulta/s responsable/s son afrodescendientes? Mamá o adulta responsable” ap19b y ap19d a “¿Tu/s mamá/s, papá/s o persona/s adulta/s responsable/s son afrodescendientes? Papá o adulto responsable”. No obstante, ap19b y ap19d fueron descartadas en pasos anteriores porque tenían un porcentaje de faltantes mayor al 75 %.

¹¹El código de la variable personas en el hogar es “ap15” y el de la variable número de habitaciones el “ap14”.

¹²El listado final de variables empleadas puede encontrarse en el siguiente enlace: https://github.com/lpezzarini-source/machine-learning-pruebas-aprender-argentina/blob/main/inputs/lista_variables.xlsx

Teniendo en cuenta que en este trabajo el análisis se realiza a nivel escuela, todas las variables relevadas a nivel estudiante y docente fueron agregadas a nivel establecimiento.¹³ En el caso de las variables numéricas, como el número de personas por habitación en cada hogar, se calcularon promedios simples por escuela, mientras que las variables categóricas son primero convertidas a *dummies* y luego se computa el porcentaje de estudiantes o docentes de la escuela en cada categoría. De este modo, cada categoría se representa como una variable distinta. Por ejemplo, en el caso del nivel educativo de los padres, cuya pregunta admite siete posibles respuestas,¹⁴ cada una de estas categorías se traduce en una variable que indica el porcentaje de estudiantes de la escuela cuyo padre o madre se encuentra en dicho nivel educativo. En este paso también se crean las variables número de alumnos por escuelas —utilizada como pesos en los modelos— y cantidad de secciones por escuela.

Finalmente, analizaron los valores faltantes a nivel escuela. En algunos casos, como edad del director (406 faltantes) y del docente (87 faltantes), se imputan utilizando promedios. Adicionalmente, en el cuestionario de directivos y en el de docentes, se observó un bloque de preguntas con la misma cantidad de valores faltantes. En este caso, se crea una variable *dummy* “contesta/no contesta” por bloque (para mayor detalle, ver Cuadro 6.1 en el Anexo).

2.2. Análisis descriptivo de los datos

La base utilizada para la construcción de los modelos está compuesta por 11.357 escuelas. Del total, el 68,3 % pertenecen al sector estatal y el resto al sector privado. En cuanto a la distribución geográfica, la Provincia de Buenos Aires (PBA) concentra el 36,8 % de los establecimientos de la muestra, seguida por Córdoba (9 %), Santa Fe (7,8 %) y la Ciudad Autónoma de Buenos Aires (CABA) (7,3 %). En conjunto, estas cuatro jurisdicciones agrupan aproximadamente el 61 % de las escuelas del país. En el otro extremo se encuentran tres provincias del sur, que son aquellas con la menor participación en la muestra (ver Figura 2.1).

¹³Este procedimiento no se aplica a las variables del cuestionario de directores, ya que hay un solo un miembro del equipo directivo por escuela.

¹⁴Las categorías son: no fue a la escuela, primaria incompleta, primaria completa, secundaria incompleta, secundaria completa, terciario/universitario/posgrado incompleto y terciario/universitario/posgrado completo

2. Datos




Figura 2.1: Distribución del total de escuelas por provincia. Participación en porcentaje (%).

El promedio de estudiantes por escuela con buen desempeño en ambas materias fue de 46,1 %.¹⁵ Sin embargo, los resultados son heterogéneos según sector y jurisdicción. En el sector privado, el 65 % de los alumnos obtuvo nivel satisfactorio o avanzado en ambas materias, mientras que en el sector estatal el porcentaje fue del 37,4 %. A nivel territorial, la CABA presentó el mejor desempeño, con 65,5 % de los estudiantes en niveles satisfactorios o avanzados en promedio por escuela, seguida por Córdoba (55 %), también por encima de la media. En el extremo opuesto, Chaco (30,5 %), Catamarca (31,5 %), Santiago del Estero (35 %), San Juan (36,3 %) y La Rioja (36,5 %) exhibieron resultados más de 10 puntos porcentuales por debajo del promedio nacional (ver Figura 2.2).

¹⁵Para calcular este promedio, primero se calcula el porcentaje de alumnos por escuela que obtuvieron resultado satisfactorio o avanzando en ambas materia. Luego se calcula el promedio simple de todas las escuelas.




Figura 2.2: Porcentaje de alumnos por escuela con resultados satisfactorio o avanzado en ambas materias (%), segmentados según sector (izquierda) y jurisdicción (derecha).

Al analizar los resultados por tamaño de escuela, los promedios son similares entre los establecimientos chicos, medianos y grandes.¹⁶ Sin embargo, la dispersión se reduce a medida que aumenta el tamaño de los establecimientos, como se puede ver en el panel izquierdo de la Figura 2.3. En cuanto al desempeño según el clima escolar¹⁷, se advierte una relación positiva entre esta variable y el desempeño. En las escuelas con clima escolar negativo, el porcentaje promedio de estudiantes con resultados satisfactorios o avanzados es de 36,3%; en aquellas donde el clima escolar intermedio, el porcentaje promedio es igual a 47,8%, y en las escuelas de clima escolar positivo, el porcentaje promedio asciende a 52,7% (ver el panel inferior de la Figura 2.3).

¹⁶Las escuelas fueron clasificadas en chicas, medianas y grandes según terciles de la cantidad de alumnos de sexto grado. Las escuelas chicas tienen hasta 33 alumnos, las medianas hasta 59, y las grandes hasta 259, con un promedio de 86 alumnos.

¹⁷Este índice es calculado por el Ministerio de Capital Humano a partir de cuatro preguntas del cuestionario de estudiantes, que indagan si el alumno recibió o ejerció maltrato, amenazas o agresiones entre pares.

2. Datos




Figura 2.3: Porcentaje de alumnos por escuela con resultados satisfactorio o avanzado en ambas materias, segmentados de según tamaño de la escuela (izquierda) y el clima escolar (derecha).

En la Figura 2.4 se presentan las 10 variables con las mayores y menores correlaciones con el desempeño por escuela. Las variable con mayor correlación positiva es el índice de NSE, y le siguen las variables que componen a este índice.¹⁸ El nivel educativo de los padres y la tenencia de determinados bienes y servicios -componentes del índice de NSE-, aparecen entre las variables con correlaciones más altas. Adicionalmente, se destacan el porcentaje de alumnos que nunca repitieron y la tenencia de libros en el hogar en formato papel, específicamente la opción entre 51 a 100 libros en el hogar.

Entre las correlaciones negativas también se hallan variables vinculadas al NSE. La primera corresponde a personas por habitación, indicador de nivel de hacinamiento. Luego, aparecen las mismas variables que en el gráfico de correlaciones positivas pero representando a las categorías más bajas dentro de cada variable. Por ejemplo, cuánto mayor el porcentaje de alumnos en la escuela con padres que no terminaron la primaria, peor es el desempeño escolar promedio del colegio. Algo similar sucede cuánto mayor el porcentaje de alumnos que declara vivir en un hogar donde no hay libros o hay solo entre 1 y 5 libros.

En el caso de la asistencia al jardín de infantes, se observa que a una mayor proporción de alumnos que asistió únicamente al jardín de 5 años lo que implica una menor exposición a experiencias educativas más tempranas, a los 3 o 4 años— se asocia con un menor desempeño escolar promedio. Por último, también se destaca en las variables con correlación negativa que a mayores responsabilidades en el hogar, como cuidar a un familiar o ayudar a un familiar en su trabajo, menor es el porcentaje de estudiantes con resultado satisfactorio o avanzado.

¹⁸El índice de NSE no se incluye como predictor en los modelos, sino que se utilizan las variables que lo componen. En cambio, el índice de NSE se reporta en la sección descriptiva de los datos para ilustrar la elevada correlación positiva con el desempeño escolar.




Figura 2.4: Correlación entre el porcentaje de alumnos por escuela con resultados satisfactorio o avanzado en ambas materias y las variables de los cuestionario. Arriba: correlaciones positivas. Abajo: correlaciones negativas.

Por último, se explora un conjunto de variables categóricas vinculadas al ámbito institucional. En particular, se analiza el bloque de preguntas del cuestionario de directores, en el que se indaga si distintos factores, como el ausentismo docente, los problemas de convivencia o la escasez de insumos, afectan el rendimiento o el aprendizaje de los estudiantes. Esta pregunta tiene tres opciones de respuestas: 1. “Sí”, que significa que, según la opinión del directivo, la problemática afecta el rendimiento y/o aprendizaje; 2. “No”, si el directivo considera que la problemática no afecta; 3. “No sucede”, si el directivo responde que la problemática no está presente en la escuela.

La Figura 2.5 muestra que las problemáticas que presentan mayores diferencias entre categorías son el ausentismo de los estudiantes, el ausentismo docente y la escasez de insumos. Respecto al ausentismo de los estudiantes, el porcentaje promedio de alumnos con buen desempeño es de 39 % en las escuelas donde el directivo considera el ausentismo como un problema y del 56 % en las escuelas donde el directivo responde que “No sucede”. En cuanto al ausentismo docente y a la escasez de insumos, el porcentaje promedio de alumnos con buen desempeño es de 39 % en las escuelas donde es un problema y del 52 % en las escuelas donde no sucede.

2. Datos




Figura 2.5: Porcentaje de alumnos por escuela con resultados satisfactorio o avanzado en ambas materias según las distintas problemáticas que afectan el desempeño.

Seguidamente, en la Figura 2.6 se muestran otras dos variables de interés: las horas que los estudiantes pasan en el escuela y la antigüedad en el cargo del director.

Respecto a la duración de la jornada, en las escuelas con jornadas más extensas, de 6 horas (1.024 escuelas) o 7 horas (1.955 escuelas), o incluso de 5 horas (4.416 escuelas), el porcentaje promedio de alumnos con buen desempeño se ubica entre 47 % y 48 %, mientras que en aquellas con jornadas de 4 horas (3.487 escuelas) el promedio es de 44 %. También se observa una diferencia con las escuelas con apenas 3 horas de clase, cuyo porcentaje de alumnos con buen desempeño es del apenas el 32 %, pero son sólo 16 escuelas. Por otro lado, en las escuelas en las que el director no posee experiencia, el porcentaje promedio de alumnos con resultado satisfactorio o avanzado es del 44 %, mientras que en aquellas cuyo director tienen entre 11 y 20 años de antigüedad, el porcentaje de alumnos con buen desempeño asciende al 48 % en promedio, y en las que cuentan con directores con más de 20 años de antigüedad el porcentaje asciende al 57 %. Sólo 330 de las escuelas tiene un director con más de 20 años de experiencia, mientras que en 5.616 los directores no tienen experiencia en el cargo.




Figura 2.6: Porcentaje de alumnos por escuela con resultados satisfactorios o avanzados en ambas materias según cantidad de horas que asisten a la escuela (izquierda) y antigüedad del director en el cargo (derecha).

CAPÍTULO 3

Metodología

En los últimos años, el uso de modelos predictivos de *machine learning* se expandió considerablemente en el campo de la educación, tanto en los niveles primario, secundario y superior. A partir de estos enfoques, es posible abordar problemas de predicción relacionados con el desempeño estudiantil, entre ellos, resultados de exámenes, riesgo de abandono y riesgo de repitencia.

Diversos trabajos de revisión de la literatura documentan el crecimiento reciente de estudios orientados a predecir el desempeño de los estudiantes mediante herramientas de *machine learning*. Por ejemplo, Albreiki et al. (2021) [1], revisaron 78 publicaciones entre 2009 y 2021. Entre ellas, 30 fueron publicadas en la primera parte del período, mientras que las 48 restantes en la segunda parte, mostrando un crecimiento del 60 % entre el primer período y el segundo. Adicionalmente, Sekeroglu et al. (2021) [24] analizaron 176 trabajos publicados entre 2010 y 2020, señalando que el uso de *machine learning* en el campo de la educación se observa sobre todo a partir de 2015. Más del 80 % de los trabajos que analizaron fueron publicados entre 2016 y 2020, mientras que el resto entre 2010 y 2015. Más recientemente, Chen et al. (2025) [4], reúne 68 trabajos publicados en revistas de alto impacto.¹ Del total, 16 trabajos fueron publicados entre 2016 y 2020, mientras que 51 entre 2021 y 2024.

Una de las grandes ventajas que destacan los trabajos mencionados es la buena *performance* predictiva de los modelos de *machine learning*. Esta característica la atribuyen a la capacidad de manejar un gran número de predictores y de capturar relaciones no lineales e interacciones complejas entre los predictores y la variable dependiente. A su vez, los modelos basados en árboles de decisión, como *Random Forest* y *Gradient Boosted Trees* (como *XGBoost*, *LightGBM* o *CatBoost*), se encuentran entre los modelos no lineales más utilizados (Chen et al. 2025 [4]; Almalawi et al. 2021 [2]), no solo en educación, sino también otras áreas diversas como finanzas, medicina o biología (Lundberg et al. 2019) [17].

Sin embargo, la alta precisión para predecir que se logra a partir del uso de estos algoritmos tiene un costo, la dificultad para interpretar los resultados. Esto es, entender cómo estos modelos usan el conjunto de variables para predecir los resultados. Más aún, cuando estas interpretaciones están presentes en los trabajos de investigación, son generalmente interpretaciones globales —¿cómo impacta una variable a nivel global en el modelo?— y mucho menos atención reciben las interpretaciones locales —¿cómo impacta la variable a una observación en particular o un grupo de observaciones?—. El método de los valores *Shap* (SHapley Additive exPlanations) resulta una buena alternativa para resolver esta tensión entre precisión e interpretabilidad. Además, constituye una herramienta de gran utilidad para brindar explicaciones locales (Lundberg & Lee, 2017; Lundberg et al., 2019)[17] [16].

Liu et al. (2022) [15] y Huang et al. (2024) [12] son dos trabajos recientes que utilizan *machine learning* para predecir el desempeño de los estudiantes en las pruebas PISA. Ambos señalan la tensión entre precisión e interpretación y utilizan el método de los valores *Shap* para interpretar los resultados de los modelos entrenados (para una explicación más acabada sobre su funcionamiento

¹Incluyen únicamente artículos de revista publicados en revistas con JCRs en Q1–Q2.

ver sección 4.2.1).² A su vez, los dos trabajos seleccionan al algoritmo *XGBoost* como el más preciso dentro de los modelos entrenados.

En el presente trabajo se entrenan dos tipos de algoritmos de *machine learning*, *Random Forest* y *XGBoost*. Estos algoritmos pertenecen a la familia de *tree ensemble models* o modelos basados en conjunto de árboles, que consisten en la combinación muchos árboles de decisión débiles para producir un predictor fuerte y más estable que los árboles tomados de forma individual.

Random Forest. Es un modelo que utiliza la técnica de *bagging* para combinar un conjunto de árboles individuales. La misma consiste en generar múltiples copias *bootstrap*³ del conjunto de entrenamiento, para luego ajustar árboles en paralelo sobre cada muestra. Luego, la predicción final surge del promedio de todos los árboles entrenados. Una característica central de estos modelos es que, en cada partición del árbol, se consideran un subconjunto aleatorio de variables, reduciendo la correlación entre los árboles y disminuyendo la varianza.

Para mejorar el desempeño predictivo de los modelos es necesario seleccionar un conjunto adecuado de hiperparámetros. Entre estos hiperparámetros se encuentran el número de árboles, su profundidad, la cantidad de predictores a utilizar en cada partición de los árboles, el número de muestras *bootstrap*, la cantidad mínima de hojas a considerar para realizar una partición y la medida de impureza para minimizar en cada partición (James et al., 2021 [13]).

Extreme Gradient Boosting (XGBoost). A diferencia de los modelos *Random Forest* que se basan en la técnica de *bagging* para combinar los árboles, *XGBoost* utiliza la técnica de ensamblado de *boosting*. Aquí, los árboles se construyen secuencialmente, a diferencia del *Random Forest* donde se constrúan de forma paralela. En cada paso, el nuevo árbol se entrena para corregir los errores del modelo anterior, definido como la diferencia entre el valor real y el valor predicho. A su vez, la contribución de cada árbol a la predicción final se reduce con una tasa de aprendizaje (un número entre 0 y 1), de modo que el modelo avanza de a poco, evitando el sobreajuste. Otra de las diferencias que tienen estos modelos con el *Random Forest*, es que no usa muestras *bootstrap* ni árboles independientes. En su lugar, trabaja siempre sobre la misma muestra e incorpora las correcciones.

Para controlar el sobreajuste, *XGBoost* aplica penalizaciones que limitan la complejidad de los árboles. Además, para hacer al modelo más estable, pueden seleccionarse submuestras de observaciones y variables. Entre los hiperparámetros se incluyen algunos de los anteriormente mencionados que intervienen en el *Random Forest*, como por ejemplo, la máxima profundidad de los árboles; además, se incluyen la tasa de aprendizaje —que cuanto más pequeña, más lento aprende el algoritmo y menor el riesgo de sobreajuste—, así como también una tasa que penaliza la complejidad del modelo, es decir que determina si hay que partir una hoja, también evitando el sobreajuste (James et al, 2021).[13]

²Utilizan la variante del método de los valores *Shap* conocida como *TreeShap*, desarrollado por Lundberg y Lee (2017), por ser el algoritmo que mejor se adapta a los modelos *XGBoost* —que ambos trabajos terminan seleccionando como el modelo más preciso— y rapidez computacional.

³Una muestra *bootstrap* es una submuestra obtenida de la muestra original y que se obtiene a partir de la selección de observaciones con reemplazo.

CAPÍTULO 4

Resultados

En esta sección se presentan los principales hallazgos del trabajo. Se describen, por un lado, los modelos entrenados y los resultados obtenidos, junto a distintas métricas de evaluación de la capacidad predictiva de los modelos. Luego, se interpretan los resultados a partir de los valores *Shap*, lo que permite comprender no solo la importancia global de cada variable en el modelo, sino también la dirección y magnitud de su contribución. La sección de interpretación se organiza a su vez en tres partes: primero, se examina la relevancia global de las variables y de las categorías de factores que explican el desempeño; además, se analiza la distribución de los efectos a nivel de variable individual. Finalmente, se profundiza en un ejercicio específico orientado a comprender por qué algunas escuelas de NSE bajo logran desempeños altos, explorando los factores que parecen permitirles compensar o mitigar las desventajas socioeconómicas.

4.1. Modelos entrenados

A continuación, se describen los modelos utilizados para predecir el desempeño educativo de las escuelas en las pruebas Aprender 2023. Se entrenan dos algoritmos de aprendizaje ensamblados: *Random Forest* y *XGBoost*. La muestra de escuelas se divide aleatoriamente en un conjunto de entrenamiento (80 %) y un conjunto de prueba (20 %). Para cada uno de los modelos se realiza la selección de hiperparámetros mediante una búsqueda exhaustiva (*Grid Search*) con validación cruzada de cinco particiones (*5-fold cross-validation*). A su vez, se utiliza como ponderador a la cantidad de alumnos por escuelas que contestaron ambos exámenes. En el Cuadro 4.1 se presenta la grilla de hiperparámetros considerada y la combinación óptima seleccionada para cada modelo.

Una vez identificado el mejor conjunto de hiperparámetros para cada modelo, se compara el desempeño entre los modelos seleccionados, utilizando la raíz cuadrada del error cuadrático medio (RMSE) y error absoluto medio (MAE) como métricas de evaluación.¹ Tal como se observa en el Cuadro 4.2, los resultados son similares para ambos modelos, mostrando el *XGBoost* un rendimiento levemente superior.

No obstante, al contrastar las métricas de evaluación de cada modelo en el conjunto de entrenamiento y de testeo, se observa un mayor sobreajuste en el modelo *Random Forest*, ya que los errores en las muestras de testeo duplican a los errores de la muestra de entrenamiento. En *XGBoost*, como es de esperar, también los valores de los errores en el conjunto de prueba son menores a los de test, pero la diferencia es menor que en el caso anterior.

Por estos motivos, la sección 4.2, dedicada a la interpretación de los resultados, se desarrolla tomando al modelo *XGBoost* como referencia.²

¹También se calculó el error porcentual absoluto medio (MAPE). No obstante, debido a la presencia de escuelas cuyo porcentaje de alumnos con resultado satisfactorio o avanzado es cercano a cero, para esas escuelas estos errores resultan muy grandes. Los mismos van disminuyendo en la medida en que se eliminan los percentiles extremos de la distribución de la variable dependiente. Por ejemplo, cuando se considera la muestra completa, el MAPE del test del *XGBoost* es de 25,9 % y del train set de 16,3 %; cuando se consideran los desempeños reales de entre el percentil 5 y 95, los MAPE son de 21,1 % y 13,2 %, respectivamente; y cuando se excluyen los percentiles 10 y 90, los valores son 19,1 % y 12,1 %.

²Como ejercicio de robustez, se estimaron los modelos sobre distintas submuestras de establecimientos: (i) escuelas

4.2. Interpretación de los resultados a partir del uso de los valores *Shap*

Cuadro 4.1: Grillas y combinaciones óptimas de hiperparámetros.

Modelo	Grilla de hiperparámetros	Combinación óptima
Random Forest	n_estimators: [200, 500, 800] max_depth: [10, 20, 30] min_samples_leaf: [1] min_samples_split: [4, 6] min_weight_fraction_leaf: [0.0002] max_features: [0.3, 0.5, 'sqrt'] max_samples: [0.6, 0.7, 0.8] bootstrap: [True] criterion: ['squared_error']	n_estimators: 500 max_depth: 20 min_samples_leaf: 1 min_samples_split: 4 min_weight_fraction_leaf: 0.0002 max_features: 0.5 max_samples: 0.8 bootstrap: True criterion: squared_error
XGBoost	n_estimators: [200, 500] max_depth: [6, 10, 20] learning_rate: [0.01, 0.05] min_child_weight: [150, 300] subsample: [0.6, 0.7] colsample_bytree: [0.3, 0.5] reg_alpha: [0, 0.1] reg_lambda: [1] gamma: [0.005] objective: ['reg:squarederror']	n_estimators: 500 max_depth: 6 learning_rate: 0.05 min_child_weight: 300 subsample: 0.7 colsample_bytree: 0.3 reg_alpha: 0 reg_lambda: 1 gamma: [0.005] objective: ['reg:squarederror']

Cuadro 4.2: Métricas de evaluación de los modelos entrenados.

Modelo	MAE		RMSE	
	Train	Test	Train	Test
Random Forest	0,041	0,084	0,058	0,113
XGBoost	0,053	0,080	0,072	0,108

4.2. Interpretación de los resultados a partir del uso de los valores *Shap*

En la sección 4.1 buscamos predecir el desempeño de las escuelas en las pruebas Aprender de 2023. El objetivo de esta sección es interpretar el funcionamiento del modelo, es decir, describir la forma en que el algoritmo utiliza las variables para predecir. Para esto, se utiliza el método de los valores *Shap*.

La gran ventaja que presentan los valores *Shap* respecto de otros métodos de interpretación de resultados de modelos basados en árboles, es que permiten analizar el impacto de las distintas variables en cada predicción individual. Gracias a esto, es posible realizar un análisis en distintos niveles (Huang et al. 2023 [12]):

1. Por un lado, es factible realizar un el análisis global, que permite identificar cuáles son las variables que, en el promedio de la muestra total de escuelas, tienen mayor incidencia en la predicción del modelo. Para ello, se calcula el promedio de los valores absolutos de los valores *Shap* individuales de cada variable y luego se ordenan las variables según su importancia relativa.

de gestión estatal y de gestión privada analizadas por separado; (ii) subconjuntos por región; y (iii) especificaciones con un conjunto reducido de predictores, integrado por las variables más relevantes según los valores *Shap* y la medida clásica de feature importance. En todos los casos, el desempeño predictivo resultó comparable al del modelo base o levemente inferior, sin cambios sustantivos en las conclusiones.

4. Resultados

2. Por otro lado, en el plano local o individual, el análisis se orienta a descomponer la predicción de cada observación individual (en este caso, el desempeño de cada escuela) y a evaluar cómo contribuye cada variable a ese resultado específico (¿cómo impacta la repitencia en una escuela determinada de Córdoba?). Esto permite extender este enfoque a grupos de observaciones, promediando los valores *Shap* de cada variable dentro de un grupo determinado, y de esta forma, comparar la importancia relativa de las variables entre diferentes grupos de interés.

En esta sección, el análisis de los valores *Shap* del modelo seleccionado se divide en tres partes. En primer lugar, se realiza un análisis global, para identificar qué variables son más relevantes en las predicciones del modelo a nivel del conjunto completo de datos de entrenamiento. En segundo lugar, considerando las variables más influyentes obtenidas del análisis global, más otras variables que se consideran de interés, se comparan las distribuciones de las variables con sus respectivos valores *Shap*. El objetivo de este ejercicio es explorar la relación entre la distribución de las variables y su aporte a la predicción del modelo. Concretamente, el ejercicio permite responder preguntas como: ¿qué sucede cuándo disminuye la proporción de estudiantes que no han repetido nunca en una escuela? ¿La contribución de esa variable a la predicción es positiva o negativa? ¿Cómo cambia la contribución marginal de una variable a medida que varía su valor? ¿El efecto se mantiene, se revierte o tiene puntos de inflexión? Finalmente, los valores *Shap* permiten agrupar y contrastar los predictores más relevantes entre esos grupos de interés. En particular, en este trabajo se explora por qué, dentro del grupo de escuelas con NSE bajo, algunas escuelas obtienen buenos resultados y otros no. Dicho de otra manera, la pregunta que guía este ejercicio es "¿Cuáles son los factores que explican que, entre las escuelas con bajo NSE, haya algunos más resilientes que otras?". Analizando qué variables explican estas diferencias, se pueden identificar factores clave asociados al desempeño educativo más allá del contexto de origen de los alumnos.

4.2.1. Introducción teórica a los valores *Shap*

El uso de modelos de *machine learning* se ha expandido con rapidez debido a su gran capacidad predictiva. Sin embargo, este avance ha puesto en evidencia una limitación central: la falta de interpretabilidad. A medida que los algoritmos se vuelven más complejos, se incrementa también la dificultad para comprender el funcionamiento de estos modelos o la forma en que estos realizan una determinada predicción. En este contexto, el método de *Shapley Additive exPlanations* (o valores *Shap*), constituye una herramienta novedosa para entender cómo un modelo de *machine learning* toma decisiones.

Los valores *Shap* descomponen la predicción de un modelo en contribuciones individuales de cada variable, lo que permite interpretar con mayor claridad el comportamiento de algoritmos complejos. Es decir, cuando un modelo hace una predicción, cada variable que este utiliza como insumo aporta en mayor o menor medida a esa predicción. El aporte puede ser positivo (la variable empuja la predicción hacia arriba), negativo (la empuja hacia abajo) o neutro. En términos prácticos, esto significa que es posible descomponer la predicción del desempeño en las pruebas Aprender de una escuela en dos partes:

1. Un valor de referencia o valor base, que es el promedio de las predicciones del modelo en todas las escuelas.
2. La suma de los aportes de cada variable para esa escuela en particular.

Es decir, la fórmula puede expresarse como:

$$\hat{y}_i = y_{\text{base}} + \sum_{j=1}^m \phi_{ij},$$

donde $\hat{y}_i$ es la predicción para el escuela i , y_{base} es el promedio de las predicciones de todas las escuelas, y ϕ_{ij} es la contribución de la variable j en ese escuela. Si $\phi_{ij} > 0$, entonces la variable j aumenta la predicción en esa escuela; si es negativa, la reduce.

Por ejemplo, la escuela identificada con el ID 655200011799486 corresponde a un escuela pública de Córdoba, de NSE bajo y que tiene 45 alumnos en sexto grado. La predicción para esta escuela puede descomponerse de la siguiente manera:

$$\underbrace{\hat{y}_i}_{78,9\%} = \underbrace{\hat{y}_{\text{base}}}_{45,8\%} + \underbrace{\sum_{j=1, j \neq 22}^m \phi_{ij}}_{27,7\%} + \underbrace{ap_{22_1}}_{4,4\%},$$

donde $\hat{y}_i = 78,9\%$ corresponde a la predicción del desempeño de la escuela i que realiza el modelo, $\hat{y}_{\text{base}} = 45,8\%$ es la predicción base (la misma para todas las escuelas), $\phi_{i,22_1} = 4,4\%$ es el valor *SHAP* de la variable “porcentaje de alumnos por escuela que no repitieron nunca”, y $\sum_{j=1, j \neq 22}^m \phi_{ij} = 27,7\%$ es la suma de los valores *SHAP* del resto de las variables.

El 4,4 % representa el aporte de la variable *ap22_1* a la predicción final de esa escuela. En este caso, como el valor de la variable es 100 % (ningún alumno repitió en esa escuela), su efecto específico es sumar 4,4 puntos porcentuales al porcentaje de alumnos con resultados satisfactorios predicho para esta escuela. De este modo, esta característica particular contribuye de manera positiva a explicar por qué la predicción final es superior al promedio.

4.2.2. Resultados globales

La Figura 4.14 representa el aporte en términos de valores *Shap* de las siguientes categorías de variables: Factores del hogar (incluye, entre otras, las variables vinculadas al nivel socioeconómico); Factores individuales (por ejemplo, actividades que realizan los estudiantes en el tiempo libre —como crear contenido para redes sociales—, con quién vive el alumno y el tiempo que tarda en llegar a la escuela); Factores institucionales (características de docentes y directivos, como antigüedad y nivel de formación); Trayectoria escolar (entre las que se encuentran la repitencia, asistencia al jardín de infantes, entre otras); y, por último, Factores de contexto, que incluye sector de gestión, jurisdicción y provincia.³ Cada barra muestra la contribución promedio agregada de todas las variables que pertenecen a esa categoría. Operacionalmente, primero se calcula, para cada variable, el promedio del valor absoluto de *Shap* sobre todas las observaciones del conjunto de entrenamiento, alrededor de 9000 escuelas; luego, esos promedios de valores absolutos se suman dentro de cada categoría. Si bien los valores agregados a nivel categoría no tienen una interpretación directa —no deben ser interpretados como si en promedio la categoría empujara la predicción base en 11,3 puntos porcentuales para el caso de Factores del hogar—, representan una primera aproximación para comprender cuáles son los factores que más inciden en el desempeño educativo.

³El listado final de variables empleadas puede encontrarse en el siguiente enlace: https://github.com/lpezzarini-source/machine-learning-pruebas-aprender-argentina/blob/main/inputs/lista_variables.xlsx

4. Resultados




Figura 4.1: Promedio del valor absoluto de los valores *Shap* globales según categoría.

En el Cuadro 4.3 se desglosan las primeras cinco variables por categoría, ordenadas en función de su valor *Shap* promedio medido en términos absolutos. Los valores se interpretan de la siguiente manera. La variable que indica el porcentaje de alumnos con computadora en el hogar mueve la predicción base, en promedio, ± 2 puntos porcentuales. Es importante señalar que estas contribuciones no deben leerse como efectos causales o impactos directos, sino como descomposiciones aditivas de la predicción del modelo en función de los valores de las variables. Es decir, la importancia de cada variable representa el efecto sobre la predicción del modelo de incluir a esa variable [16].

4.2. Interpretación de los resultados a partir del uso de los valores *Shap*

Cuadro 4.3: Principales variables por categoría según su valor *Shap* promedio medido en términos absolutos).

Factores del hogar	Factores individuales	Trayectoria escolar	Factores institucionales	Factores de contexto
Tenencia de libros (3,3 p.p)	¿Realiza las siguientes actividades? Buscar agua potable o leña (1,2 p.p)	Repitencia (2 p.p)	Problemas de convivencia en la escuela (0,3 p.p)	Jurisdicción (1,8 p.p)
Tenencia de computadora (2 p.p)	Tiempo en llegar a la escuela (1,1 p.p)	Opinión sobre la resolución de problemas de matemática (1,3 p.p)	Cuántas horas trabaja en la escuela el docente (0,2 p.p)	Sector de gestión (1,1 p.p)
Nivel educativo de la madre (1,3 p.p)	¿Realiza las siguientes actividades? Cultivar o cosechar (1 p.p)	Faltas al colegio (1,1 p.p)	Clima escolar (0,2 p.p)	Región (0,2 p.p)
Nivel educativo del padre (1,1 p.p)	¿Realiza las siguientes actividades? Crear contenidos para redes sociales (0,9 p.p)	Asistencia al jardín de infantes (0,9 p.p)	Antigüedad del director en el cargo (0,2 p.p)	–
Personas por habitación (1 p.p)	¿Realiza las siguientes actividades? Tareas del hogar (0,8 p.p)	Opinión sobre la resolución de problemas de geometría (0,9 p.p)	Acceso del director al cargo (0,2 p.p)	–

En la categoría Factores del hogar, en la que se agrupan diecinueve variables, cuatro de las principales conforman el índice de NSE. La restante, cantidad de libros presentes en el hogar donde reside el alumno, guarda relación con estas variables. Los principales predictores de esta categoría se alinean con la literatura, que investiga el efecto de los factores libros en el hogar, la tenencia de computadora, el nivel educativo de los padres y el hacinamiento como predictores habituales del rendimiento educativo. Por ejemplo, en OCDE (2024) [20], utilizando datos de las pruebas PISA, analizan la disminución de la cantidad de libros en los hogares entre 2015 y 2022, advirtiendo sobre la relación positiva que existen entre esta variable y el desempeño educativo. Castro et al. (2018) [3], en un estudio centrado en países de América Latina, señalan que la tenencia de más libros en el hogar se asocia con mejores resultados en lectura. Este último trabajo también analizan el efecto de la educación de la madre y el padre en el desempeño educativo, señalando las diferencias regionales. En cuanto a la tenencia de computadora en el hogar, Odell et al. (2020) [21] revisan 25 publicaciones sobre la relación entre el uso de Tecnologías de la Información y la Comunicación (ICT) y el desempeño en matemáticas y ciencia en las pruebas PISA. Encuentran que los resultados varían según la materia, el país⁴, el tipo de tecnología y la intensidad de uso. Por último, respecto a la variable hacinamiento, Contreras et al.(2019) [5] analizan si este factor tiene un efecto negativo en los países de América Latina. Muestran que, aún controlando por nivel socioeconómico y otras variables asociadas a la pobreza, el hacinamiento tiene un efecto negativo y estadísticamente significativo sobre el desempeño académico. Usando datos para quince países, los autores encuentran que este efecto es tan marcado que llega a superar el impacto del nivel educativo materno en varios contextos.

⁴El concepto de ICT no solo alude a la computadora, sino que también incluye dispositivos digitales y diversas tecnologías orientadas a compartir información y facilitar la comunicación entre usuarios, tales como software, hardware y redes.

4. Resultados

La categoría Factores individuales, agrupa veinticinco variables. Tres de las cinco más relevantes hacen referencia a la frecuencia con la que el alumno realiza determinadas actividades por fuera de la escuela. Estas actividades no tienen que ver con el ocio o recreación, sino más bien son tareas de cuidado o colaboración en el hogar. Concretamente, las preguntas son: “Durante la semana pasada, ¿hiciste lo siguiente? ¿por cuánto tiempo?” sobre una serie de actividades/tareas, entre las que aparecen: buscar leña o agua afuera de la casa, tareas del hogar (Realizar distintas tareas como limpiar, lavar platos o ropa, cocinar, hacer las compras, cuidar animales domésticos, etc), cultivar o cosechar en la huerta, ordeñar o cuidar animales de granja o campo para consumir ⁵. En un trabajo reciente para India, Sharma et al.(2025) [25] encuentran que el tiempo dedicado al trabajo doméstico no remunerado aparece como un predictor común del desempeño educativo: mayores horas de tareas domésticas se asocian con mayor probabilidad de discontinuar la escuela, más ausentismo y menores habilidades de lectura y aritmética, especialmente entre mujeres.⁶ Los resultados de Wang et al.(2022) [28] contrastan con los anteriores. Utilizando datos de China, encuentran que realizar tareas domésticas con frecuencia se asocian, en general, con un mejor desempeño académico en primaria y secundaria, especialmente cuando la carga no es excesiva.

Las otras dos variables con mayor aporte dentro de la categoría Factores Individuales son “Tiempo en llegar a la escuela”, cuyas opciones van desde “menos de 30 minutos” a “más de dos horas” y si durante su tiempo libre el estudiante crea contenido para redes sociales (Youtube, Tik-Tok, Instagram, entre otras opciones). Con respecto al tiempo de viaje a la escuela, ver por ejemplo Filmer et al.(2007) [10], que analizan la relación entre distancia a la escuela y matrícula escolar y encuentran una asociación estadísticamente significativa aunque de magnitud reducida. Por último, respecto a la creación de contenidos en redes sociales, se trata de un objeto de estudio más reciente que los anteriores y aún menos explorado. Ji & Pang (2023) [14], investigan los efectos del uso de redes sociales por parte de los estudiantes sobre resultados en las pruebas PISA 2018, señalando que el efecto varía entre países.⁷

La categoría Trayectoria escolar engloba a ocho variables en total, las cuales también han sido consideradas en la literatura especializada como factores relevantes para el desempeño educativo. Cuatro de ellas indagan la opinión del estudiante respecto a determinadas competencias: resolución de problemas de matemática, de geometría, lectura y escritura.⁸ Esta categoría también contempla las variables repitencia⁹, sobreedad, faltas y asistencia al jardín de infantes¹⁰.

La variable que hace referencia a la repitencia es la más importante dentro de esta categoría y generalmente tiene una asociación negativa con el desempeño escolar. Castro et al.(2018) [3] encuentra resultados similares al analizar el impacto de la repitencia en países de Latinoamérica. Sostienen que no repetir tiene un efecto positivo en los puntajes y que es mayor en Argentina y en Brasil. La asistencia al jardín de infantes y faltas a la escuela también aparecen dentro de las principales cinco variables dentro de esta categoría. Con respecto a la primera, la asistencia al jardín, ver por ejemplo en UNESCO (2015) [27], donde se señala que la educación preescolar entre los 4 y 6 años se asocia de manera positiva y significativa con los logros académicos posteriores, un patrón que se replica en prácticamente todos los países de América Latina evaluados. Respecto a las faltas o ausentismo, el mismo trabajo señala que la inasistencia a clase posee una relación negativa y significativa con el desempeño en la mayoría de los países analizados.

Además, dentro de las variables vinculadas a la opinión sobre competencias individuales, aparecen opinión sobre resolución de problemas de matemática y opinión sobre problemas de geometría. Estas pueden asimilarse a las variables que en el contexto de las pruebas PISA componen el índice

⁵Las opciones de respuesta son “Nunca realicé esta tarea”, “Algunos días”, “De lunes a viernes”, “Todos los días”.

⁶Definen este tipo de trabajo como la realización de actividades rutinarias del hogar, que incluyen “cocinar, limpiar, buscar alimentos, recolectar agua, recolectar leña, hacer compras para las necesidades diarias y cuidar a niños y otros miembros del hogar”.

⁷Cabe señalar que esta variable no refiere a la creación o publicación de contenido en redes sociales, sino al uso de plataformas como Facebook o MySpace para comunicarse con otros estudiantes sobre cuestiones escolares. En PISA, la variable se construye a partir de la pregunta: “How often use social networks such as Facebook and MySpace for communication with other students about school-related matters”.

⁸El estudiante puede contestar “Muy bien”, “Bien”, “Regular” o “Mal”

⁹Las respuestas posibles son “No”, “Sí, una vez”, “Sí, dos veces”, “Sí, tres veces o más”.

¹⁰Las opciones de respuesta son “No fui”, “Sí, desde sala de 3 o antes”, “Sí, desde sala de 4”, “Sí, desde sala de 5”.

de autoeficacia en matemática (*mathematic self-efficacy*), construido a partir de la respuesta de los estudiantes sobre cómo perciben su habilidad para resolver determinados problemas de matemática (OCDE, 2022)[19]. Además, el hallazgo es consistente con Huang et al.(2024) [12], que ubican a la autoeficacia en matemática entre los factores de mayor peso en la predicción del rendimiento en matemática, y con Yang et al. (2024) [29], que, utilizando los exámenes NAEP 2019 en Estados Unidos, destacan a la autoeficacia en matemática como un predictor robusto del desempeño.

La categoría de Factores institucionales —que agrupa setenta y tres variables— incluye características del docente, de los directivos y de la institución (horas de clase, existencia de clases de apoyo, de normas de convivencia, entre otras). También en el caso de estas variables es posible encontrar referencia en la literatura sobre su rol como predictoras del desempeño escolar. Por ejemplo, Grissom et al.(2019) [11], destacan la importancia de la estabilidad y antigüedad del director en el funcionamiento escolar, y encuentran que una alta rotación directiva se asocia con menor rendimiento de los estudiantes. Mientras que Elaqua & Marotta (2019) [8] señalan que cuando los docentes tienen que trabajar en muchas escuelas (menos horas en cada una), el desempeño empeora y afecta más a los estudiantes de bajos ingresos. Por último, dentro de la categoría Factores de contexto, se destacan los valores *Shap* de las variables Jurisdicción y Sector de gestión.

Tommasi et al. (2025) [26] analizan los determinantes del rendimiento en las pruebas Aprender. Utilizando un modelo de regresión encuentran que, entre las características del hogar, la asistencia a sala de tres, el nivel socioeconómico promedio y la cantidad de libros en el hogar son factores estadísticamente significativos. Mientras que, entre los factores institucionales, emergen, entre otros, el clima escolar y la antigüedad del director, en línea con los factores identificados en el presente trabajo.

4.2.3. Relación entre la distribución de las variables y los valores *Shap*

En este apartado se explora la relación que existe entre la distribución de las variables y sus respectivos valores *Shap*. Se trata de un análisis de carácter descriptivo, basado en el análisis de distintos gráficos. Estos permiten, por ejemplo, examinar la contribución de la variable repitencia a la predicción del modelo y caracterizar el signo y la magnitud de dicho efecto. En particular, el análisis permite evaluar si una mayor o menor proporción de alumnos por escuela que no han repetido se asocia con un mejor o peor desempeño promedio en las pruebas Aprender 2023. Asimismo, posibilita indagar si la intensidad de esta contribución se mantiene constante a lo largo del rango de la variable o si, por el contrario, varía a partir de ciertos umbrales.

Las variables que se exploran son aquellas que surgieron como las más relevantes en el análisis global de valores *Shap*. Se utiliza la misma categorización de la sección anterior, de modo tal de facilitar el análisis: factores del hogar, factores individuales del alumno, trayectoria escolar, factores institucionales y factores de contexto. Para las variables categóricas se utilizan *boxplots*, que permiten comparar la distribución de los valores *Shap* según cada categoría, mientras que para las variables continuas se emplean *scatterplots*.

Factores del hogar

Las cinco variables más importantes surgidas de la sección anterior son tenencia de computadora, cantidad de libros formato papel en el hogar, máximo nivel educativo alcanzado por la madre y el padre y personas por habitación. Se utiliza la variable tenencia de computadora para explicar cómo deben ser interpretados los gráficos.

La Figura 4.2 muestra la relación entre el porcentaje de alumnos por escuela con computadora en el hogar (eje X) y sus valores *Shap* (eje Y). Cada punto corresponde a una escuela y el color indica su NSE (a mayor NSE, más oscuro el color con el que se representa a la escuela). En el gráfico se distinguen tres tramos:

4. Resultados

1. Cuando el porcentaje de alumnos con computadora en el hogar está entre el 0 % y el 50 % (eje X), los valores *Shap* son siempre negativos y la correlación entre estos y la variable (porcentaje de alumnos en la escuela con computadora en el hogar) es levemente positiva (0,2), lo que significa que los incrementos en la tenencia de computadora casi no se traducen en mejoras en el desempeño del colegio.
2. Cuando el porcentaje de alumnos con computadora en el hogar está entre el 50 % y el 70 %, los valores *Shap* siguen siendo negativos (en promedio son de -1,2). No obstante, la pendiente positiva es pronunciada, siendo la correlación cercana a la unidad (0,9).
3. Cuando el porcentaje de alumnos con computadora en el hogar está cercano al 70 %, todas las escuelas exhiben valores *Shap* positivos y relativamente altos. Para estas escuelas, la contribución promedio de esta variable es en promedio 2,7 puntos porcentuales por encima del valor esperado (son el 40 % de las escuelas de la muestra). La correlación sigue siendo positiva y elevada.

En síntesis, la tenencia de computadoras en el hogar muestra un efecto positivo y significativo sobre el desempeño escolar sólo cuando el acceso alcanza niveles medios o altos. Específicamente, el impacto comienza a ser significativo a partir de que al menos la mitad de los alumnos dispone de computadora en su hogar, y se vuelve más favorable cuando la cobertura supera el 70 %. Por debajo de ese umbral, los incrementos en el acceso tienen un efecto marginal y limitado sobre el rendimiento promedio de la escuela.

A su vez, se puede dividir el gráfico en regiones. Allí observamos que, al comparar las zonas A y B, que presentan porcentajes de tenencia similares pero distinto NSE, las escuelas con NSE más alto obtienen un retorno mayor de la tenencia, reflejado en valores *Shap* más positivos. Esta diferencia puede explicarse por varios factores. En primer lugar, existe un efecto en red: cuando una mayor proporción de estudiantes en escuelas con alto NSE tiene acceso a computadoras, es más probable que surjan prácticas pedagógicas, tareas y dinámicas escolares que integren efectivamente la tecnología, generando beneficios colectivos. Además, los hogares con mayor NSE suelen contar con capacidades complementarias más desarrolladas, como mayor nivel educativo de los padres, habilidades digitales previas, apoyo en las tareas, mejor conectividad y espacios adecuados de estudio, que les permiten aprovechar mejor el acceso a la tecnología. Finalmente, las escuelas con NSE más alto tienden a disponer de mejor infraestructura institucional (equipamiento tecnológico, conectividad estable y docentes con formación digital), lo que amplifica el impacto positivo del acceso a computadoras.




Figura 4.2: *Shap* values de la variable porcentaje de alumnos por escuela con computadora en el hogar y el valor de la variable.

Las restantes variables más relevantes dentro de la categoría Factores del hogar son los niveles educativos de la madre, del padre, libros en el hogar y personas por habitación.

Con relación al nivel educativo de los padres, dada la forma en que se construyeron estas variables —una variable por nivel educativo (ver detalles en la sección 2.1)—se obtuvieron siete gráficos para la madre y siete para el padre. Los patrones más claros en la relación entre la distribución de la variable y los valores *Shap* se evidencian en los niveles primaria incompleta y terciario/universitario/posgrado incompleto.

Respecto al nivel primaria incompleta, en la Figura 4.4 se observa que los valores *Shap* positivos se dan sólo en la zona donde el porcentaje de alumnos con padres con esa característica es cercana a cero.¹¹ Para el nivel terciario/universitario/posgrado completo, cuando se trata de la madre, el punto de a partir del cual los valores *Shap* comienzan a ser positivos se encuentra entre el 35 %/40 %, promediando 1,1 puntos porcentuales cuando el valor supera el 80 %. Para el caso de los padres, el porcentaje a partir del cual el aporte de la variable comienza ser positivo es similar y el valor *Shap* promedio para las escuelas que superan ese umbral es de 1 punto porcentual. En los cuatro gráficos se observa un patrón claro respecto al NSE: en los gráficos de la categoría primaria incompleta (izquierda), las observaciones en más oscuras se encuentran a la izquierda, indicando que las escuelas con NSE alto tienen un bajo porcentaje de madres y padres con primaria incompleta (solo alrededor del 1 % de las madres y padres en estas escuelas alcanzó ese nivel educativo). Las observaciones de NSE bajo se ubican más a la derecha, indicando lo contrario (el 14 % de las madres y el 15 % de los padres tienen estas características). En el caso de los gráficos de la derecha, correspondiente a las categorías terciario, universitario o posgrado completo, son las escuelas con NSE alto las que se encuentran a la derecha (mayor porcentaje de estudiantes con madres y padres con este nivel educativo): en promedio, en estas escuelas, el 75 % de las madres y el 65 % alcanzaron este nivel educativo, mientras que en las escuelas con NSE bajo esos porcentajes descienden a 17 % y 15 % respectivamente.




Figura 4.3: Porcentaje de alumnos con madres que alcanzaron los niveles educativos primaria incompleta y terciario/universitario/posgrado completo y sus valores *Shap* correspondientes.

¹¹Las escuelas con valores *Shap* positivos en los gráficos de la variable primaria incompleta tienen un porcentaje de madres con esta característica de apenas el 2 % y del 3,7 % para el caso de los padres.

4. Resultados




Figura 4.4: Porcentaje de alumnos con padres que alcanzaron los niveles educativos primaria incompleta y terciario/universitario/posgrado completo y sus valores *Shap* correspondientes.

Las otras dos variables vinculadas a características del hogar que se analizan son la Tenencia de libros en formato papel en el hogar (la opción que se grafica es “No posee libros en formato papel en el hogar”) y el número de personas por habitación (ver Figura 4.5). Para ambas variables, la relación es negativa: cuanto mayor el porcentaje de alumnos que responden no tener libros en el hogar o mayor el número de personas por habitación en el hogar, el efecto de la variable en la predicción del modelo es más negativo. Además, en ambos casos se observa la segmentación entre escuelas de mayor y menos NSE.




Figura 4.5: Porcentaje de alumnos según tenencia de libros en el hogar (izquierda) y número de personas por habitación (derecha) y sus valores *Shap* correspondientes.

Trayectoria escolar

Del análisis de los valores *Shap* globales (ver sección 4.2.2), surgen las siguientes variables: repitiencia, opinión sobre resolución de problemas de matemática y de geometría, asistencia al jardín de infantes y número de faltas a la escuela.

La variable porcentaje de alumnos por escuela que no repitieron nunca es la de valores *Shap* más elevados en términos absolutos (Figura 4.6). Por un lado, existe una correlación positiva entre el porcentaje de alumnos que no repitieron y sus valores *Shap*. Por el otro, la relación no es lineal. La correlación para valores menores del 80 % es de 0,3, mientras que para el tramo 80 %-100 % de 0,96. Además, a partir de los valores 85 %/90 %, los valores *Shap* comienzan a ser positivos, con un valor promedio de 2,2 puntos porcentuales para el 17 % de las escuelas en las que ningún estudiante de

sexto grado repitió. También hay una asociación positiva entre NSE y la distribución de la variable; en las escuelas de menor NSE el porcentaje de alumnos que no repitieron es menor: en promedio, el porcentaje de alumnos por escuela que nunca repitieron es del 79 % en las escuelas de NSE bajo y del 97 % en las de NSE alto.




Figura 4.6: Porcentaje de alumnos por escuela que nunca han repetido y sus valores *Shap* correspondientes.

En cuanto a la asistencia al jardín de infantes (Figura 4.7), el patrón más claro se observa en el nivel sala de tres o antes y en sala de cinco. Los valores *Shap* son positivos a partir del 50 % de alumnos por escuela con asistencia a la sala de tres. Son las escuelas de mayor NSE las que muestran los mayores porcentajes de asistencia, y por lo tanto, mayores valores *Shap*. Lo contrario ocurre con el nivel sala de cinco, las escuelas con mayor porcentaje de alumnos que asistieron al jardín a partir de la sala de cinco son las de menor NSE. A su vez, la pendiente es negativa y los valores *Shap* para esta categoría son negativos a partir de un porcentaje de alumnos con estas características superior al 10 %/15 %.

4. Resultados




Figura 4.7: Porcentaje de alumnos por escuela según asistencia al jardín y sus valores *Shap* correspondientes.

En cuanto a las variables que indagan sobre la opinión de los alumnos acerca de cómo resuelven cálculos de matemática y problemas de geometría (dos variables separadas) (ver Figuras 4.8 y 4.9) se grafican las opciones de los extremos: el porcentaje de alumnos por escuela que contesta “Muy bien” y el porcentaje de alumnos por escuela que contesta “Mal”. Para la variable opinión sobre resolución de cálculos de matemática, se observa que, a mayor porcentaje de alumnos que contesta “Muy bien”, mayor el valor *Shap* de la variable. Complementariamente, a menor el porcentaje que contesta “Mal”, mayor el valor *Shap* de la variable. Para la variable opinión sobre resolución de problemas de geometría, la relación más contundente se refleja cuando los alumnos contestan “Mal”.




Figura 4.8: Porcentaje de alumnos por escuela según su opinión acerca de cómo resuelve cálculos de matemática y sus valores *Shap* correspondientes.




Figura 4.9: Porcentaje de alumnos por escuela según su opinión acerca de cómo resuelve problemas de geometría y sus valores *Shap* correspondientes.

Por último, en cuanto a las faltas por escuela, la relación entre la distribución de la variable y sus valores *Shap* tampoco es lineal. Además, el sentido de la relación va en contra de lo esperado: cuando el porcentaje de alumnos que no faltó nunca es menor al 10 %, los valores *Shap* son sistemáticamente positivos (Figura 4.10 panel derecho). A su vez, al considerar la categoría entre 10 y 15 faltas, se observa una relación positiva entre esta variable y sus correspondientes valores *Shap*.

4. Resultados




Figura 4.10: Porcentaje de alumnos por escuela según cantidad de faltas y sus valores *Shap* correspondientes.

Factores individuales

Las variables de esta categoría que se analizan son: “La semana pasada, ¿hiciste lo siguiente? ¿por cuánto tiempo? [Realizar distintas tareas como limpiar, lavar platos o ropa, cocinar, hacer las compras, cuidar animales domésticos, etc.]”, “La semana pasada, ¿hiciste lo siguiente? ¿por cuánto tiempo? [Buscar agua o leña fuera de casa]”, “La semana pasada, ¿hiciste lo siguiente? ¿por cuánto tiempo? [Cultivar o cosechar en la huerta, ordeñar o cuidar animales de granja o campo para consumir]”, “Aproximadamente, ¿cuánto tiempo tardás en llegar a la escuela?” y “Durante tu tiempo libre, ¿hacés lo siguiente? Crear contenidos para redes sociales (YouTube, Twitch, Instagram, Tik-Tok, etc.)”.

Las tres primeras variables están relacionadas con tareas domésticas o de colaboración en el hogar. La opción que se grafica es la respuesta que indica que el alumno no realizó la tarea ningún día de la semana. Los gráficos de la parte superior de la Figura 4.11 tienen pendiente positiva, lo cual indica que, cuanto mayor el porcentaje de estudiantes por escuela que no realizan este tipo de actividad, mayor es el aporte de la variable a la predicción del modelo. Los valores *Shap* se vuelven sistemáticamente positivos recién a partir de umbrales altos (alrededor del 90 % en la primera variable y del 95 % en la segunda). En conjunto, esto sugiere que no realizar estas tareas se asocia positivamente con el rendimiento escolar. Además, son los estudiantes de menor NSE quienes más frecuentemente sí realizan estas tareas (en los gráficos, esto se refleja como un menor porcentaje en el eje X).¹².

La tercera variable del grupo pregunta: “La semana pasada, ¿hiciste lo siguiente? ¿por cuánto tiempo? [Realizar distintas tareas como limpiar, lavar platos o ropa, cocinar, hacer las compras, cuidar animales domésticos, etc.]”. A diferencia de las variables anteriores, la pendiente es negativa, indicando que la colaboración de los alumnos en estas tareas del hogar se asocia de forma positiva con un mayor rendimiento. Tampoco se observa un patrón entre la distribución de la variable y el NSE promedio de las escuelas. Una hipótesis para este comportamiento, opuesto al de las primeras dos variables, es que estas tareas generales del hogar no reflejan de manera directa condiciones de vulnerabilidad socioeconómica, sino que tienden a estar presentes en la mayoría de los hogares, por lo que su efecto podría capturar hábitos de organización o conductas dentro del hogar más que carencias materiales.

¹²Los porcentajes encontrados son consistentes con indicadores del Censo 2022. Por ejemplo, aunque el uso de leña o carbón como combustible es 1,4 % a nivel país, en Misiones, Formosa y Santiago del Estero —provincias con menores índices promedio de NSE— supera el 8 %; y el acceso a agua por cañería dentro de la vivienda alcanza el 93,9 % en promedio nacional, pero baja del 80 % en Formosa, Chaco y Santiago del Estero. Datos disponibles en <https://portalgeoestadistico.indec.gob.ar/>

4.2. Interpretación de los resultados a partir del uso de los valores *Shap*




Figura 4.11: Porcentaje de alumnos por escuela que no realizó la actividad ningún día de la semana y sus valores *Shap* correspondientes.

La variable que refiere al tiempo que el estudiante tarda en llegar a la escuela admite cuatro respuestas: menos de treinta minutos, entre treinta minutos y una hora, entre una y dos horas y más de dos horas. Se grafica la primera opción (Figura 4.12) (menos de treinta minutos) porque exhibe el patrón más nítido entre la distribución de la variable, su valor *Shap* y el índice de NSE. La relación no es estable: cuando menos del 70 % de los estudiantes de una escuela tarda menos de treinta minutos, la correlación es positiva pero baja (0,2) y los valores *Shap* son negativos (−0,7 en promedio). En el tramo 70 %–95 % la correlación es cercana a la unidad (0,9) y a partir del 95 % se mantiene alta (alrededor de 0,6). Además, la distancia afecta más a los hogares de menor NSE: en escuelas donde más del 30 % de los alumnos demora más de 30 minutos, el *Shap* promedio es −1,3 para NSE bajo, −0,8 para NSE medio y −0,5 para NSE alto. En síntesis, el gráfico sugiere que el tiempo en llegar a la escuela afecta negativamente al rendimiento escolar y que a su vez, penaliza más a los estudiantes de menor NSE.

4. Resultados




Figura 4.12: Porcentaje de alumnos por escuela que tarda menos de 30 minutos en llegar a la escuela y sus valores *Shap* correspondientes.

Por último, la creación de contenidos para redes sociales se asocia de manera negativa con el desempeño (Figura 4.13): un porcentaje alto de alumnos que crea contenidos en las redes sociales se relaciona de forma negativa con el rendimiento escolar. En promedio, para las escuelas con porcentaje menor al 30 % —alrededor del 18 % de las escuelas— el valor *Shap* promedio es de 1,7 puntos porcentuales positivo mientras que para las escuelas donde el porcentaje es mayor al 50 % (19 % de las escuelas), el valor *Shap* promedio es de -1,6 puntos porcentuales. Además, los valores *Shap* son más positivos para las escuelas con NSE bajo.




Figura 4.13: Porcentaje de alumnos por escuela que crea contenido en las redes sociales y sus valores *Shap* correspondientes.

Factores de contexto

Las variables que se encuentran en esta categoría son jurisdicción, región y sector de gestión. En el Cuadro 4.4 se presentan medidas de resumen sobre los valores *Shap* de estas variables. En el caso de jurisdicción, los valores mínimo y máximo son de -4 y 10,6 respectivamente. Tomando como referencia el valor base de porcentaje de alumnos con nivel satisfactorio o avanzado que predice el modelo (45,8 %), el valor *Shap* de -4 puntos porcentuales indica que, para esa escuela, el modelo predice que el porcentaje de alumnos con resultado satisfactorio o más es 4 puntos porcentuales menos que la predicción base y lo atribuye a la pertenencia de esa escuela a la jurisdicción de Santa

Cruz. A su vez, le otorga 10,6 puntos porcentuales por encima de la predicción base a una escuela por ser de la provincia de Córdoba.

Cuadro 4.4: Promedios, mínimos y máximos de los valores *Shap* de las variables categóricas.

Variable	Promedio	Mínimo	Máximo
Jurisdicción	0,5	-4	10,6
Sector de gestión	0,02	-1,5	3,2
Región	0	-1,8	0,3

En la Figura 4.14 se muestran *boxplots* por sector de gestión (arriba) y por jurisdicción (abajo). Se grafican sólo estas dos variables dado que la variable región presenta baja variabilidad, en tanto su efecto queda en gran medida absorbido por la variable jurisdicción.

En cuanto al sector de gestión, los valores *Shap* para las escuelas privadas son siempre positivos, mientras que para las escuelas públicas son siempre negativos. Respecto a las jurisdicciones, las que más sobresalen son Formosa y Córdoba, con valores *boxplots* promedio para la variable “jurisdicción” de 4,3 y 4 respectivamente; en menor medida, destacan CABA y Corrientes con un valor promedio de 1,6. En el extremo opuesto se ubican las jurisdicciones de Santa Cruz (-2,2 en promedio), Catamarca (-1,4) y La Rioja (-1,1 en promedio). El caso de Santa Cruz es particularmente extremo: los valores son negativos en todas las escuelas, con un promedio de -2,2 puntos porcentuales y un mínimo de -4 puntos porcentuales. Cabe reiterar que el análisis de los valores *boxplots* no debe interpretarse en términos de causalidad ni supone que el efecto estimado pueda atribuirse de manera directa y exclusiva a una variable determinada. Además, los valores *Shap* pueden estar recogiendo la influencia de factores no observados en el cuestionario o reflejando correlaciones con otras variables efectivamente incluidas, pero cuya contribución marginal es absorbida por la variable en cuestión.




Figura 4.14: Distribución de los valores *Shap* por sector de gestión (arriba) y jurisdicción (abajo).

Factores institucionales

Entre las variables vinculadas al entorno institucional se analizan las siguientes: problemas de convivencia según la opinión del director, índice de clima escolar, cantidad de horas que trabaja

4. Resultados

el docente en la escuela, antigüedad del director en el cargo y procedimiento mediante el cual el director accedió al cargo. Como se plasma en el Cuadro 4.3. Las variables de la categoría Factores institucionales son las que poseen valores *Shap* globales más reducidos.

Con relación a las primeras dos variables, si bien están relacionadas, se construyen de forma diferente. Por un lado, el índice de Clima escolar se compone de cuatro preguntas del cuestionario de estudiantes sobre si el alumno recibió o ejerció maltrato, amenazas o agresiones entre pares; en cambio, problemas de convivencia surge del cuestionario de directores (“Según su criterio, ¿los siguientes factores afectan los procesos de enseñanza y aprendizaje de las y los estudiantes de 6.º grado de esta escuela? [Problemas de convivencia entre estudiantes]”). En ambos gráficos se observa que un clima escolar negativo o la presencia de problemas de convivencia se asocian con peores desempeños: los valores *Shap* resultan negativos. Por el contrario, cuando el índice de clima escolar es positivo, los valores *Shap* son positivos en promedio, aunque de magnitud moderada, de 0,24 promedio, mientras que, si el director indica que los problemas de convivencia no afectan o no suceden en la escuela, los valores *Shap* son cercanos a cero, ver Figura 4.15.




Figura 4.15: Distribución de los valores *Shap* según las variables Problemas de convivencia e Índice de clima escolar.

Por otro lado, se encuentran las variables vinculadas a las características del director: antigüedad en el cargo de director y forma de acceso al cargo. En cuanto a la antigüedad, los valores *Shap* más negativos corresponden a escuelas en las cuales el director no tiene antigüedad, que son el 11 % de las escuelas. Mientras que los valores *Shap* para las escuelas cuyo director posee una antigüedad mayor a 20 años se ubican en el rango de 0 a 1,6 puntos porcentuales. En cuanto a la forma en que el director accedió al cargo, los valores *Shap* son bajos, cercanos a cero y las categorías con valores más positivos son “Por proceso de selección definido por la institución u otra manera”, como muestra la Figura 4.16.

4.2. Interpretación de los resultados a partir del uso de los valores *Shap*




Figura 4.16: Distribución de los valores *Shap* según Antigüedad del director en el cargo de director y forma de acceso al cargo.

Finalmente, en relación con la cantidad de horas que el docente trabaja en la escuela, se observa una relación positiva entre los valores *Shap* y la carga horaria. Si bien las magnitudes de los valores *Shap* no son elevadas, el patrón indica que a medida que el docente concentra más horas de trabajo en un mismo establecimiento, el desempeño de la escuela mejora.




Figura 4.17: Distribución de los valores *Shap* según la cantidad de horas que el docente trabaja en la escuela.

4.2.4. Diferencias en el desempeño entre las escuelas de NSE bajo

El objetivo de esta sección es explicar por qué, dentro del grupo de escuelas con NSE bajo, algunas de ellas logran alcanzar un mejor desempeño escolar en promedio, mientras en la mayoría de ellas, el desempeño está por debajo del promedio. En otras palabras: ¿por qué algunas escuelas de NSE bajo son más resilientes que otras? ¿Cuáles son las variables que se destacan para explicar las diferencias en el desempeño entre grupos?

El primer paso de este ejercicio consiste en segmentar a las escuelas según su NSE. La base de datos de las Aprender 2023 ofrece una categorización de los alumnos en función de su puntaje

4. Resultados

de NSE (bajo, medio y alto). Sin embargo, esta clasificación indica que alrededor del 74 % de los estudiantes es de NSE medio y tan solo al 10,7 % de NSE bajo, lo cual contrasta con las estadísticas socioeconómicas oficiales de Argentina. Por este motivo, en este trabajo se opta por una regla alternativa, inspirada en Edo, Sosa-Escudero y Svarc (2021)[9], que definen la clase baja como el percentil 25 de un índice multidimensional para 2004–2014¹³. En este trabajo se opta por actualizar el umbral y considerar el umbral de NSE bajo al percentil que replica la tasa promedio de indigencia en menores de 14 años en 2022–2023. Operativamente, se clasifica como NSE bajo a las escuelas ubicadas por debajo del percentil 33 del índice NSE reportado en las pruebas Aprender 2023.¹⁴

A partir de esta segmentación, dentro del grupo de escuelas con NSE bajo se clasifican a 2957 establecimientos, otras 897 en el grupo de NSE alto 897 y 5107 en el grupo de NSE medio.

Luego de segmentar a las escuelas según NSE, se realiza una segunda segmentación basada en el desempeño, definiendo las categorías alto, medio y bajo. Para llevar a cabo el ejercicio de esta sección, donde se busca comparar a las escuelas de NSE bajo con desempeño bajo por un lado, y a las escuelas de NSE bajo y buen desempeño por el otro, es necesario contar con un número de colegios considerable dentro de cada grupo, principalmente dentro del grupo NSE bajo y desempeño alto. Como se observa en la Figura 4.18, a medida que aumenta el porcentaje de alumnos con resultado satisfactorio a avanzando requerido para categorizar a la escuela como escuela con buen desempeño, menor el número de escuelas en esta categoría (más detalles en el Cuadro 6.2 del Anexo). Si se toma como umbral para definir como escuelas de desempeño alto aquellas en las que al menos el 55 % de los alumnos alcanza resultados satisfactorios o avanzado —valor que se encuentra aproximadamente 10 puntos porcentuales por encima de la mediana y el promedio del conjunto total de escuelas, y coincide con el tercil superior de la distribución de desempeño— el total de escuelas en este grupo, NSE bajo y alto desempeño, asciende a 185.




Figura 4.18: Número de escuelas de NSE bajo categorizada como desempeño alto según diferentes umbrales de porcentaje de alumno por colegio con desempeño satisfactorio o más.

Por otro lado, se consideraron escuelas de desempeño bajo a aquellas en las que hasta un tercio de los alumnos logró un resultado satisfactorio o avanzado. Este punto de corte coincide con el tercil inferior de la distribución de escuelas según desempeño, es decir, los establecimientos con peor desempeño. En el Cuadro 4.5 se muestran cómo quedan conformados los grupos.

¹³Se incluyen las variables ingreso per cápita familiar, fuentes de ingreso, características de la vivienda, educación, entre otras

¹⁴De Simone, M. et al. (2022)[7], siguen una metodología similar, pero utilizan el umbral de pobreza (no indigencia) del año 2019 (40,4 %).

Cuadro 4.5: Segmentación de las escuelas con NSE bajo, según desempeño.

Desempeño	Cantidad de escuelas	Alumnos satisfactorio o avanzando (%)	NSE promedio*
Alto	185	69,1	-0,37
Medio	898	41,3	-0,26
Bajo	1.874	20,4	-0,34

* Primero se obtiene el porcentaje promedio por escuela (promediando los alumnos) y luego el promedio de las escuelas.

Representación de las provincias en los grupos de NSE bajo

La variable jurisdicción es una de las variables con valores *Shap* más elevados en términos absolutos. Esto indica que se trata de uno de los factores más importantes para explicar las predicciones del modelo. A continuación, se calcula la participación de las provincias en los dos grupos bajo análisis y se las compara con la representación en la muestra total. El objetivo es ver si:

1. Hay provincias sobrerrepresentadas en el grupo de NSE bajo y alto desempeño (185 escuelas), así como también subrepresentadas en el grupo de bajo NSE y bajo desempeño (las 1.874 escuelas). En ambos casos, indica la presencia de escuelas más resilientes en estas provincias.
2. Hay provincias sobrerrepresentadas dentro del grupo de NSE bajo y bajo desempeño o subrepresentadas en el grupo de NSE bajo y alto desempeño. Contrario a lo que sucede en los grupos descritos en el ítem anterior, en estas escuelas, los factores adicionales al NSE —como por ejemplo los institucionales, individuales o de trayectoria escolar— no alcanzan para soslayar el impacto negativo del NSE bajo.

Dentro del grupo de 185 escuelas con NSE bajo y alto desempeño, la provincia más sobrerrepresentada es Córdoba. Su participación en la base completa es 9 %, mientras que en el segmento de escuelas de NSE bajo y alto desempeño es de 22,2 %. Algo similar sucede con Misiones y Formosa, con una sobrerrepresentación de 9 puntos porcentuales. En el otro extremo, la provincia más subrepresentada dentro de las escuelas con NSE bajo y alto desempeño es Buenos Aires: su participación en la muestra completa es del 36,8 % pero del 14,1 % en el segmento analizado (ver Figura 4.19)




Figura 4.19: Comparación participación de las provincias en el segmento NSE bajo y alto desempeño y en la muestra completa

4. Resultados

Entre las provincias sobrerrepresentadas dentro del conjunto de 1.874 escuelas con NSE bajo y desempeño bajo, aparecen las provincias de menor NSE en la muestra total (con excepción de Entre Ríos, que es una provincia con NSE medio). Dentro de las subrepresentadas, las que más sobresalen son CABA y Córdoba (ver Figura 4.20).




Figura 4.20: Comparación participación de las provincias en el segmento NSE bajo y bajo desempeño y en la muestra completa

Luego de segmentar las escuelas, se utilizan los valores *Shap* para precisar cuáles son las características más salientes que explican las diferencias entre los grupos. En el Cuadro 4.6 se agregan los valores *Shap* según las categorías definidas anteriormente: Factores del hogar, Factores individuales, Trayectoria escolar, Factores de contexto y Factores institucionales.

Para el segmento con NSE bajo y bajo desempeño, todas las categorías impulsan la predicción del modelo hacia abajo, principalmente los Factores del hogar, Factores individuales y Trayectoria escolar. Por otro lado, en los colegios de NSE bajo pero alto desempeño, si bien el aporte de los factores del hogar sigue siendo negativo, la magnitud es menor. Esto implica que, a pesar de tener un contexto vulnerable, el efecto en el desempeño es menos negativo que para el grupo anterior. El resto de los factores aporta de forma positiva al grupo de NSE bajo y desempeño alto.

Cuadro 4.6: Valores *Shap* agregados, según categoría de NSE y desempeño.

Categoría	Factores del hogar	Factores individuales	Trayectoria escolar	Factores institucionales	Factores de contexto	Total
Alto	-1,5	2,2	2,5	1,0	1,0	5,2
Medio	-5,4	-1,3	-1,1	-0,1	-0,9	-8,8
Bajo	-8,2	-6,2	-4,2	-0,6	-1,8	-21

En lo que sigue, se analizan las diferencias entre ambos grupos de la siguiente forma. Primero, se identifican las variables con mayores valores *Shap* positivos para el conjunto de escuelas de NSE bajo y desempeño alto. Luego, las variables con valores *Shap* más negativos para las escuelas de NSE bajo y bajo desempeño. Por último, considerando todas las variables, se pone el foco en cuáles se encuentran las diferencias más grandes entre ambos grupos.

Variables que empujan hacia arriba la predicción de las escuelas con NSE bajo y desempeño alto

Las variables más importantes para explicar el buen desempeño predicho para las escuelas de NSE bajo y rendimiento alto (aquellas con valores *Shap* positivos más elevados) son jurisdicción y creación de contenido en redes sociales. Al considerar la variable jurisdicción, los valores *Shaps* más elevados están en las provincias de Córdoba y Formosa.¹⁵ El valor *Shap* promedio es de 6,8 puntos porcentuales en Formosa y de 6,3 puntos porcentuales en Córdoba; en menor medida, en Corrientes (2,2 puntos porcentuales) y CABA (1,9 puntos porcentuales). Adicionalmente, respecto a la variable “Durante tu tiempo libre, ¿hacés lo siguiente? Crear contenidos para redes sociales (YouTube, Twitch, Instagram, Tik-Tok, etc.)”, cuando la respuesta es que no crean contenido, el aporte promedio de la variable en términos de valores *Shap* es de 0,7 puntos porcentuales, con un máximo de 5,8 puntos porcentuales. En la Figura 4.21 se observa la correlación negativa entre el porcentaje de alumnos que crea contenido en redes sociales y su valor *Shap* asociado: en las escuelas en las que una menor cantidad de estudiantes responde de forma afirmativa a la pregunta sobre creación de contenidos en redes sociales, el modelo predice un mayor nivel de desempeño.

En promedio en las escuelas de NSE bajo y desempeño alto, el 38 % de los estudiantes responde que no crea contenidos, mientras que en las escuelas de NSE bajo y bajo desempeño, el porcentaje es de 45,4 %. Para ambos grupos, el porcentaje a partir del cual los valores *Shap* comienzan a ser negativos se ubican alrededor del 45 %. En el caso de las escuelas de desempeño alto, solo el 29 % de las escuelas supera el umbral —un total de 54 escuelas—, mientras que en los de desempeño bajo el 49 % —un total de 935 escuelas—.




Figura 4.21: Porcentaje de alumnos por escuela que crea contenido en redes sociales. Distribución de la variable y valores *Shap*. Por categoría de escuela.

Jornada educativa de 6 horas en Córdoba

Córdoba es la provincia más sobrerrepresentada en el grupo de escuelas con NSE bajo y alto desempeño. Son en total 41 escuelas. Además, posee los valores *Shap* asociados a la variable “jurisdicción” más elevados, junto con Formosa. La variable jurisdicción aporta, en promedio, 6,6 puntos porcentuales por sobre la estimación base. Es decir, la pertenencia a esta jurisdicción se asocia con un mejor rendimiento promedio en las pruebas Aprender 2023. Esta variable podría estar capturando aspectos institucionales o contextuales que no aparecen explícitamente en los cuestionarios, o bien que, aun estando presentes, resultan más sintéticamente representados por la variable de jurisdicción. Adicionalmente, los valores *Shap* de la variable porcentaje de alumnos que no han repetido nunca contribuyen, en promedio

¹⁵En Tommasi et al.(2025)[26] también se destaca el buen desempeño de Formosa. Señalan además que las escuelas estatales de la provincia, a pesar de ubicarse en el cuartil 1 del índice NSE, presentan un rendimiento elevado comparado con escuelas de contexto similar.

con 1 punto porcentual.

La tercera variable que se destaca en las escuelas de Córdoba por su valor *Shap*, y que refleja un aspecto institucional, es la variable “Jornada de clases de 6 horas”. En las escuelas de NSE bajo y alto desempeño, el valor *Shap* promedio es de 0,8 puntos porcentuales —y en 10 de ellas supera 1 punto porcentual—. En las escuelas de NSE bajo y bajo desempeño con jornadas de 6 horas (74 escuelas), el valor *Shap* sigue siendo positivo aunque su contribución promedio es menor, 0,5 puntos porcentuales.

Si bien la diferencia entre ambos grupos no es particularmente grande en términos absolutos (escuelas con alto y bajo desempeño entre aquellos con NSE bajo), al realizar un test de hipótesis para evaluar la igualdad de medias entre grupos se rechazó la hipótesis nula de igualdad de medias.^a Asimismo, se observa que en todos los casos el efecto estimado es positivo: la implementación de jornadas de 6 horas aparece asociada a incrementos en la predicción del desempeño escolar, independientemente del nivel de desempeño observado. En conjunto, estos resultados sugieren que la extensión de la jornada escolar aporta de manera constante, aunque moderada, a mejorar los resultados académicos esperados según el modelo.

Los resultados encontrados para Córdoba se alinea con lo que encuentran Liu et al.(2022) [15] cuando analizan los resultados en las pruebas PISA para escuelas de 4 provincias de China. Los autores encuentran que el *learning time* (que son las horas de clase) se ubica entre los factores escolares de mayor peso para explicar el desempeño y que su contribución no es lineal: existe un punto óptimo en torno a las seis horas diarias, más allá del cual el rendimiento académico tiende a estancarse o caer.

Las jornadas extendidas en las escuelas primarias de gestión estatal comenzaron a implementarse a partir de 2010. En la base utilizada, el 88 % de las escuelas de gestión estatal de la provincia tienen jornadas de 6 horas, mientras que en el resto del país la proporción es del 3 %.

^aEl test arrojó un p-valor inferior a 0,01.

Variables que empujan hacia abajo la predicción de las escuelas con NSE bajo y desempeño bajo

¿Qué factores contribuyen de manera negativa a la predicción en las escuelas de NSE bajo y bajo desempeño? En este grupo de escuelas, las provincias de Chaco, Misiones, Santiago del Estero, Corrientes y Entre Ríos, son las que muestran una participación mayor que en la muestra total. Por el contrario, Córdoba y la CABA son las provincias subrepresentadas en el grupo de escuelas con NSE bajo y bajo desempeño.

Entre las variables con valores *Shap* negativos más bajos se encuentra la tenencia de computadora en el hogar, que en estas escuelas aporta en promedio -2 puntos porcentuales. Sin embargo, el porcentaje de alumnos con computadora es similar al de las escuelas con NSE bajo y alto desempeño, y para este grupo en promedio el valor *Shap* es de -1,3. La Figura 4.22 muestra la distribución de la variable (panel izquierdo) y del valor *Shap* asociado (panel derecho). Se observa que, en general, las escuelas con desempeño bajo están por debajo en valor *Shap* en toda la distribución. Esto sugiere que en las escuelas de NSE bajo no sólo se trata de un problema de acceso, sino de cómo este recurso se utiliza y se integra a los aprendizajes.




Figura 4.22: Distribución de la tenencia de computadora por categoría de desempeño escolar (izquierda) y distribución de los valores *Shap* de la tenencia de computadora según categoría de desempeño (derecha).

En segundo lugar aparece la variable repitencia (Figura 4.23), que en promedio aporta -1,3 puntos porcentuales y en 495 escuelas más de -2 puntos porcentuales. A diferencia de la variable anterior, en este caso sí se observan diferencias entre el porcentaje de alumnos por escuela que no repitieron, entre ambos grupos de escuela. Para los de desempeño alto, el promedio de alumnos que nunca repitieron es de 86 %, mientras que para los bajos de 77 %.




Figura 4.23: Distribución del porcentaje de alumnos que no repitieron nunca, por categoría de desempeño escolar (izquierda) y distribución de los valores *Shap* de la variable según categoría de desempeño (derecha).

El ejercicio se repitió para las diez variables con efectos más negativos sobre las escuelas con NSE bajo y bajo desempeño los valores *Shap* siempre fueron en promedio menores para el grupo de desempeño bajo.

¿Cuáles son las variables con mayor diferencia de valores *Shap* entre ambos grupos —escuelas de NSE bajo y alto desempeño y escuelas de NSE bajo y bajo desempeño—?

A diferencia de las dos subsecciones anteriores, en las que se analiza la contribución de las variables a cada grupo por separado, en esta subsección se comparan los valores *Shap* de todas las variables entre ambos grupos, reportando aquellas que presentan las mayores diferencias. Como lo evidencia el Cuadro 4.6, en promedio, para las escuelas NSE bajo y bajo desempeño, los valores *Shap* aportan -21 puntos porcentuales a la estimación base, mientras que, en las escuelas de NSE bajo pero alto desempeño, aporta 5,2 puntos porcentuales positivos. Es decir, la diferencia es de 26 puntos porcentuales.

4. Resultados

En el Cuadro 4.7 se presentan las 20 variables con mayor diferencia entre grupos. En conjunto, aportan 12 puntos porcentuales, menos de la mitad de la diferencia total. En otras palabras, la diferencia se distribuye entre un conjunto amplio de variables. Ahora bien, al analizar la distribución de cada variable, si bien en promedio los resultados tienden a favorecer a las escuelas de NSE bajo y buen desempeño (por ejemplo, el porcentaje de alumnos que no repitieron es de 77 % en los de bajo desempeño frente a 86 % en los de alto), las diferencias no parecen tan marcadas.

Una posible explicación adicional de esta brecha surge al analizar el tamaño de las escuelas. En los establecimientos de alto desempeño, el promedio de alumnos por institución es de 30,4, mientras que en los de bajo desempeño asciende a 51,6. Si bien en la estimación del modelo la cantidad de alumnos se utilizó únicamente como ponderador y no como variable explicativa, la comparación de su distribución entre ambos grupos revela una diferencia sustantiva.

Para evaluar si esta característica estructural posee un efecto independiente, se incorporó la cantidad de secciones por escuela como variable explicativa. Sin embargo, sus valores *Shap* fueron muy bajos, lo que sugiere que —al menos dentro del modelo estimado— no aporta capacidad predictiva relevante. Aun así, el contraste en el tamaño promedio de las escuelas podría estar señalando un patrón organizacional distinto entre los grupos, cuya interpretación requiere cautela, pero que podría contribuir a contextualizar los resultados observados.

A modo de cierre, es posible sintetizar los principales aportes de este capítulo en las siguientes ideas principales. En primer lugar, en el plano global, las variables con mayor influencia en las predicciones del modelo son las que pertenecen a las categorías vinculadas a los factores del hogar e individual de los estudiantes, mientras que las variables institucionales tienen un peso menor, salvo algunas excepciones.

Luego, el análisis conjunto de la distribución de las variables y sus valores *Shap* permite explorar la forma en que los efectos se manifiestan. Varios predictores exhiben relaciones no lineales, con puntos de inflexión a partir de los cuales su aporte cambia de signo o se intensifica. Tal es el caso de la repitencia, que contribuye positivamente cuando los niveles sin repitencia superan cierto umbral, o de la tenencia de computadora, que muestra aportes negativos en gran parte de la distribución y se vuelve positiva solo con niveles muy altos de acceso. Estos patrones sugieren que no basta con ampliar la cobertura de ciertos recursos, sino que es el umbral alcanzado el que logra que el efecto se traduzca en mejoras en el aprendizaje.

Adicionalmente, el ejercicio de segmentación permite profundizar en los contrastes entre dos grupos de escuelas específicos: escuelas de bajo NSE con alto y bajo desempeño. Allí se observó que, mientras los primeros son más resilientes, otros permanecen rezagados pese a condiciones de partida similares. Las diferencias no se concentran en una sola variable: las veinte con mayor diferencia en los valores *Shap*, explican menos de la mitad de la brecha, lo que revela un fenómeno más difuso y multicausal. Aun así, factores como la jurisdicción, repitencia, la creación de contenidos en redes sociales y la tenencia de computadora, aparecen como los factores más relevantes para explicar las diferencias. En conjunto, estos hallazgos subrayan que la resiliencia educativa en contextos vulnerables depende de la interacción de múltiples dimensiones —alumno, hogar, escuela y territorio—.

Por último, este ejercicio permite identificar hallazgos útiles para la política. El caso de la jornada extendida en Córdoba es ilustrativo: aunque su aporte promedio es modesto, resulta más positivo en contextos de menor NSE, lo que sugiere que la política de las seis horas de clase podría estar ayudando a compensar desventajas socioeconómicas. En conjunto, los resultados muestran que la resiliencia educativa se explica a partir de la interacción de múltiples variables y que herramientas como *Shap* permiten desagregar, revelar umbrales críticos y orientar intervenciones específicas para reducir brechas educativas y mejorar el desempeño de las escuelas.

Cuadro 4.7: Diferencias en los valores *Shap* entre escuelas de NSE bajo de alto y bajo desempeño, según variable.

% de alumnos por colegio	Promedio en escuelas de bajo desempeño (%)	Promedio en escuelas de alto desempeño (%)	Shap en escuelas de bajo desempeño (p.p)	Shap en escuelas de alto desempeño (p.p)	Diferencia valores <i>Shap</i> : alto -bajo
No repitieron nunca	77,1	86,2	-1,3	0,26	1,6
Crean contenidos en las redes sociales	45,4	37,7	-0,5	0,7	1,2
Sin libros en el hogar	20,3	16,3	-0,9	-0,22	0,9
Con computadora en el hogar	43,6	44,8	-2	-1,3	0,7
Tardan >30' en llegar a la escuela	80,4	84,7	-0,6	0,50	0,7
Duerme en casa/departamento	91,3	94,4	-0,3	0,17	0,5
No faltó nunca a la escuela	16,5	13,3	-0,38	0,1	0,5
Personas por habitación	2,1	2,1	-1	-0,6	0,5
Cuidó a un familiar todos los días	24,2	18,2	-0,3	0,1	0,4
Opina que resuelve mal problemas de Geometría	11	7,6	-0,4	0,07	0,4
Opina que resuelve mal problemas de Matemática	7,4	5,4	-0,29	0,1	0,4
No realizó tareas del hogar	16,8	14,4	-0,54	0,3	0,4
Tiene más de 100 libros en el hogar	12,6	9,3	0,32	0,4	0,4
Conexión a internet en el hogar	86,6	83,9	-0,34	0,02	0,4
Juega de manera digital	57,7	57,8	-0,5	-0,16	0,4
Posee Tablet	37,4	32,6	0,3	0,37	0,3
No tiene sobriedad	18,7	14,5	-0,27	0,03	0,3
Ayuda en trabajo a familiar todos los días	18	15	-0,35	-51	0,3
Tiene entre 6 y 20 libros en el hogar	19,8	24,8	-0,47	0,2	0,3
No buscó agua ni leña fuera del hogar	6,7	5,8	-0,35	-0,07	0,3

CAPÍTULO 5

Reflexiones finales

El objetivo de este trabajo consiste en aplicar técnicas de *machine learning* para predecir el desempeño de las escuelas argentinas en las pruebas Aprender 2023 y, al mismo tiempo, avanzar en la comprensión de los factores asociados a esos resultados. Para ello, se construyó una base a nivel escuela que integra información de los cuestionarios de estudiantes, docentes y directivos, y se estimaron modelos de árboles de decisión, en particular *Random Forest* y *XGBoost*. La combinación de estos modelos con el cálculo de los valores *Shap* permitió articular las dos dimensiones: la capacidad predictiva y la interpretabilidad.

En términos de desempeño, los resultados muestran que los modelos basados en árboles logran predecir con buena precisión el porcentaje de estudiantes con desempeño satisfactorio o avanzado en Lengua y Matemática, y que el modelo *XGBoost* presenta el mejor ajuste y una mayor capacidad de generalización de resultados. Más allá de la capacidad de predicción, el foco del análisis se encontró en los determinantes del desempeño. Agrupar las variables en cinco categorías —factores del hogar, factores individuales, trayectoria escolar, factores institucionales y factores de contexto— permitió organizar la interpretación de los valores *Shap* y dialogar con la literatura previa respecto a los determinantes del desempeño escolar. Los hallazgos pueden sintetizarse en tres planos.

En primer lugar, los resultados confirman que el contexto socioeconómico del hogar continúa siendo uno de los predictores centrales del rendimiento escolar. Variables como la tenencia de computadora, la cantidad de libros en el hogar, el nivel educativo de la madre y el padre y el hacinamiento explican una parte sustantiva de las diferencias entre escuelas. El análisis de los valores *Shap* muestra, además, que estos factores no siempre operan de manera lineal. Por ejemplo, el acceso a computadoras sólo se asocia a mejoras claras en el desempeño cuando alcanza niveles de acceso medios o altos, y los retornos son mayores en escuelas con mayor nivel socioeconómico, donde existen condiciones complementarias para aprovechar la tecnología.

En segundo lugar, se observa que existen otros factores relevante por fuera del nivel socioeconómico. Por ejemplo, en la trayectoria escolar se destacan la repitencia y la asistencia temprana al jardín de infantes. El modelo sugiere que, por encima de cierto umbral de estudiantes que nunca repitieron, la contribución de esta variable al desempeño se vuelve fuertemente positiva, mientras que iniciar la escolaridad recién en sala de cinco se asocia con peores resultados, y sucede especialmente en escuelas de menor NSE. Entre los factores individuales aparecen la autoevaluación de los estudiantes en matemática y geometría, el tiempo de viaje a la escuela y la creación de contenidos para redes sociales. El tiempo en llegar a la escuela se vincula de forma negativa con el rendimiento y penaliza más a los alumnos de menor NSE, lo que sugiere la importancia de la disponibilidad de vacantes en escuelas como política para destinadas a acortar brechas. Por su parte, un alto porcentaje de estudiantes que crea contenidos para redes sociales se relaciona, en promedio, con un menor desempeño, lo que plantea interrogantes sobre el tipo de usos de la tecnología y su posible interferencia con el tiempo de estudio.

En tercer lugar, aunque los factores institucionales tienen, en promedio, menor peso que los anteriores, algunos indicadores resultan relevantes. El clima escolar se asocia positivamente con el desempeño, así como también la antigüedad del director, sugiriendo que la rotación frecuente en estos cargos puede afectar el rendimiento escolar de los estudiantes. La jornada extendida de

seis horas, especialmente en la provincia de Córdoba, se vincula con incrementos en el redimiento escolar predicho por modelo, lo que sugiere que la ampliación del tiempo escolar podría contribuir a mejorar el desempeño educativo, en particular en contextos de menor NSE. Entre los factores de contexto, la jurisdicción y el sector de gestión concentran buena parte de la variación explicada: las escuelas privadas presentan valores *Shap* sistemáticamente positivos, mientras que, entre las provincias, algunas —como Córdoba o Formosa— destacan por sus aportes favorables, y otras por efectos negativos.

Un aporte específico del trabajo fue el análisis de las escuelas de bajo NSE. La segmentación de este grupo mostró que existe un conjunto de escuelas que, a pesar de operar en contextos vulnerables, logran un buen desempeño en las pruebas Aprender. En estas escuelas, los factores del hogar siguen teniendo un efecto negativo, pero de menor magnitud que en las escuelas de bajo NSE y bajo desempeño, mientras que los factores individuales, de trayectoria escolar, institucionales y de contexto aportan de forma positiva. Las diferencias entre las escuelas de bajo NSE con alto y bajo desempeño no se explican por una sola variable, sino por combinaciones de características: menor porcentaje de repitencia, menor uso de redes sociales o pertenencia a jurisdicciones que aparecen sobrerrepresentadas entre las escuelas resilientes. Esto sugiere que, aún cuando las condiciones socioeconómicas fijan un piso de desigualdad difícil de revertir, existen márgenes de acción capaces de morigerar parte de esas desventajas.

El trabajo tiene, sin embargo, varias limitaciones. En primer lugar, se trata de un análisis centrado en un único operativo de las pruebas Aprender, por lo que no es posible estudiar dinámicas en el tiempo ni evaluar cambios en el desempeño escolar. En segundo lugar, los resultados se basan en asociaciones estadísticas y no deben interpretarse como efectos causales: el modelo captura correlaciones entre predictores y desempeño, susceptibles de estar influenciadas por variables no observadas. En tercer lugar, aunque se utilizaron más de ciento veinte variables, la exploración detallada se concentró en los predictores más importantes dentro de cada categoría. Además, no se realizó un análisis exhaustivo de todos ellos ni de las interacciones posibles. Finalmente, el estudio se limita a escuelas urbanas y al desempeño en sexto grado de primaria, por lo que sus conclusiones no deben extrapolarse automáticamente a otros ámbitos o niveles educativos.

Estas limitaciones abren líneas claras para futuras investigaciones. Una primera dirección consiste en extender el análisis a múltiples operativos de Aprender o a otro tipo de evaluaciones, lo que permitiría estudiar la estabilidad de los patrones encontrados y explorar trayectorias en el tiempo, así como también profundizar el uso de métodos de *machine learning* en combinación con enfoques de inferencia causal, e integrar conjuntos de datos adicionales al del operativo Aprender.

En síntesis, el trabajo muestra que los modelos de *machine learning*, complementados con herramientas de interpretación como los valores *Shap*, ofrecen un marco potente para aprovechar la riqueza de los microdatos de las evaluaciones nacionales. Estos enfoques permiten no sólo predecir el desempeño de las escuelas, sino también identificar patrones y umbrales relevantes en múltiples dimensiones. Estos resultados, en combinación con estudios adicionales, pueden convertirse en un insumo valioso para el diseño de políticas educativas orientadas a reducir brechas, fortalecer la resiliencia de las escuelas en contextos vulnerables y mejorar las oportunidades de aprendizaje de los estudiantes.

CAPÍTULO 6

Anexo de tablas y gráficos

Cuadro 6.1: Tratamiento de valores faltantes e imputación de variables

Código variable	Descripción variable	Total de escuelas faltantes	Método de imputación
Edad director	Edad del director	406	Promedio
Edad docente	Edad del docente	87	Promedio
dp03a, dp20, dp03h, dp06b, dp28b, dp09a, dp48f, dp29, dp19b, dp48c, dp48d, dp03i, dp08, dp12b, dp37, dp06a, dp48j, dp48i, dp48a, dp03c, dp07, dp50b, dp03d, dp03f, dp48e, dp48g, dp09b, dp06c, dp12a, dp28c, dp48h, dp62, dp47, dp03b, dp03g, dp03e, dp01, dp50a, dp09c, dp19e, dp48b, dp28a	Ejemplos: “¿Cuál es la antigüedad de la o el director?”, “¿En qué medida la repitencia y el abandono escolar son un problema en esta escuela?”	293	Se crea una variable dummy <i>Contesta / No contesta</i> . Luego, las columnas con valor faltante se reemplazan por cero. En caso de respuesta, se asigna un valor 1 a la opción correspondiente.
mp10c, mp06, mp13e, mp13d, mp10a, mp13a, mp15b, mp13c, mp13b, mp10g, mp15a, mp09, mp10e, mp10i, mp13f, mp02, mp08, mp10f, mp22, mp10j, mp04a, mp10b, mp07a, mp25, mp10d, mp10h	Ejemplos: “¿Cuáles de los siguientes niveles educativos usted ha completado?”, “¿Cuál es su antigüedad en la docencia?”	41	Se crea una variable dummy <i>Contesta / No contesta</i> . Luego, las columnas con valor faltante se reemplazan por cero.
ap27a, ap27d, ap27c, ap21, personas_por_habitacion, ap28, migracion, ap06b, ap27b, ap17b, ap17a, ap05h, ap26, ap05f, ap29, ap13, ap23, ap05g, ap16d, ap16c, ap08, ap05c, ap06d, ap06a, ap06c, ap06e, ap05e, ap07b, ap07a, ap05d, ap05a, ap05b, ap04, ap12	Ejemplos: “Según tu opinión, ¿cómo lees?”, “¿Te gusta ir a la escuela?”, “Durante tu tiempo libre, ¿jugás de manera digital?”	Entre cinco y nueve escuelas faltantes	Promedio

6. Anexo de tablas y gráficos

Cuadro 6.2: Segmentación de colegios según categoría de NSE y de desempeño. Promedio, mediana, mínimo y máximo de porcentaje (%) de alumnos por colegio con nivel satisfactorio o avanzado

Categoría según NSE	Categoría según desempeño	Número de colegios	Promedio	Mediana	Mínimo	Máximo
Total	alto	3138	71 %	69 %	55 %	100 %
	medio	3058	43 %	43 %	33 %	55 %
	bajo	2765	21 %	23 %	0 %	33 %
alto	alto	867	79 %	79 %	55 %	100 %
	medio	48	46 %	47 %	33 %	55 %
	bajo	13	10 %	9 %	0 %	31 %
medio	alto	2088	68 %	67 %	55 %	100 %
	medio	2142	44 %	44 %	33 %	55 %
	bajo	903	24 %	26 %	0 %	33 %
bajo	alto	183	69 %	65 %	55 %	100 %
	medio	868	41 %	40 %	33 %	55 %
	bajo	1849	20 %	22 %	0 %	33 %

Bibliografía

- [1] Albreiki, B., Zaki, N., & Alashwal, H. (2021). A systematic literature review of student performance prediction using machine learning techniques. *Education Sciences*, 11(9), 552. <https://doi.org/10.3390/educsci11090552>
- [2] Almalawi, A., Soh, B., Li, A., & Samra, H. (2024). Predictive models for educational purposes: A systematic review. *Big Data and Cognitive Computing*, 8(12), 187. <https://doi.org/10.3390/bdcc8120187>
- [3] Castro Aristizabal, G., Giménez, G., & Pérez Ximénez-de-Embún, D. (2018). Estimation of factors conditioning the acquisition of academic skills in Latin America in the presence of endogeneity. *CEPAL Review*, 124, 33–50
- [4] Chen, J., Zhou, X., Yao, J., & Tang, S.-K. (2025). Application of machine learning in higher education to predict students' performance, learning engagement and self-efficacy: A systematic literature review. *Asian Education and Development Studies*, 14(2), 205–240. <https://doi.org/10.1108/AEDS-08-2024-0166>
- [5] Contreras, D., Delgadillo, J., & Riveros, G. (2019). Is home overcrowding a significant factor in children's academic performance? Evidence from Latin America. *International Journal of Educational Development*, 67, 102–110. <https://doi.org/10.1016/j.ijedudev.2019.01.006>
- [6] INDEC. (2025). *Censo Nacional de Población, Hogares y Viviendas 2022: Síntesis de resultados*. Instituto Nacional de Estadística y Censos. https://censo.gob.ar/wp-content/uploads/2025/01/censo_2022_sintesis_resultados.pdf
- [7] De Simone, M., Nistal, M., & Orlicki, E. (2022). *Desempeño escolar y pobreza*. Observatorio Argentinos por la Educación. <https://argentinosporlaeducacion.org/informe/desempeno-escolar-y-pobreza/>.
- [8] Elacqua, G., & Marotta, L. (2019). Do multiple school jobs affect teacher performance? Evidence from Brazil (IDB Working Paper Series No. IDB-WP-01051). Inter-American Development Bank. <https://doi.org/10.18235/0001889>
- [9] Edo, M., Escudero, W.S., & Svarc, M. (2021). A multidimensional approach to measuring the middle class. *J Econ Inequal* 19, 139–162. <https://doi.org/10.1007/s10888-020-09464-5>
- [10] Filmer, D. (2007). If you build it, will they come? School availability and school enrollment in 21 poor countries. *Journal of Development Studies*, 43(5), 901–928. <https://doi.org/10.1080/00220380701384588>
- [11] Grissom, J. A., Egalite, A. J., & Lindsay, C. A. (2019). How principals affect students and schools: A systematic synthesis of two decades of research. EdWorkingPaper No. 19-95. Annenberg Institute at Brown University.
- [12] Huang, Y., Zhou, Y., Chen, J., & Wu, D. (2024). *Applying machine learning and Shap method to identify key influences on middle-school students' mathematics literacy performance*. *Journal of Intelligence*, 12(10), 93. <https://doi.org/10.3390/jintelligence12100093>

- [13] James, G., Witten, D., Hastie, T., & Tibshirani, R. (2021). An introduction to statistical learning: With applications in R (2nd ed.). Springer. <https://doi.org/10.1007/978-1-0716-1418-1>
- [14] Ji, Z., & Pang, J. (2023). Social media and student academic performance: A cross-country analysis using PISA 2018. *International Journal of Educational Technology and Learning*, 15(1), 28–37. <https://doi.org/10.55217/101.v15i1.687>
- [15] Liu, H., Chen, X., & Liu, X. (2022). Factors influencing secondary school students' reading literacy: An analysis based on XGBoost and *Shap* methods. *Frontiers in Psychology*, 13, 948612. <https://doi.org/10.3389/fpsyg.2022.948612>.
- [16] Lundberg, S.M. & Lee, S.I. (2017). A Unified Approach to Interpreting Model Predictions. *Proceedings of the 31st NIPS Conference*, 4766–4777. <https://doi.org/10.48550/arXiv.1705.07874>
- [17] Lundberg, S. M., Erion, G., Chen, H., DeGrave, A., Prutkin, J. M., Nair, B., Katz, R., Himmelfarb, J., Bansal, N., & Lee, S.-I. (2020). From local explanations to global understanding with explainable AI for trees. *Nature Machine Intelligence*, 2(1), 56–67. <https://doi.org/10.1038/s42256-019-0138-9>
- [18] Ministerio de Capital Humano. (2023). Evaluación Nacional Aprender 2023. Gobierno de Argentina. <https://www.argentina.gob.ar/educacion/evaluacion-informacion-educativa/aprender/aprender-2023>.
- [19] Organisation for Economic Co-operation and Development. (2022). *Definitions (PISA 2022)*. Education GPS. https://gpseducation.oecd.org/content/notes/definitions_pisa_gps.pdf.
- [20] OECD. (2024). Fewer books and more educational software: How have home learning environments changed since 2015? *PISA in Focus*, No. 127. OECD Publishing. <https://doi.org/10.1787/0e179a87-en>
- [21] Odell, B., Cutumisu, M., & Gierl, M. (2020). A scoping review of the relationship between students' ICT and performance in mathematics and science in the PISA data. *Social Psychology of Education*, 23, 1435–1462. <https://doi.org/10.1007/s11218-020-09591-x>
- [22] Salari, N., Zarei, H., Rasoulpoor, S., Ghasemi, H., Hosseinian-Far, A., & Mohammadi, M. (2022). The impact of social networking addiction on the academic achievement of university students globally: A meta-analysis. *Public Health in Practice*, 3, 100249. <https://doi.org/10.1016/j.puhip.2022.100249>
- [23] Secretaría de Educación de la Nación. (2023). *Informe de resultados Aprender 2023*. Ministerio de Capital Humano, Subsecretaría de Información y Evaluación Educativa. Recuperado de https://www.argentina.gob.ar/sites/default/files/aprender_2023_final.pdf
- [24] Sekeroglu, B., Abiyev, R., Ilhan, A., Arslan, M., & Idoko, J. B. (2021). Systematic literature review on machine learning and student performance prediction: Critical gaps and possible remedies. *Applied Sciences*, 11(22), 10907. <https://doi.org/10.3390/app112210907>
- [25] Sharma, A., & Shah, A. (2025). The role of time spent in unpaid domestic work on educational outcomes among adolescents and young adults: Quantitative evidence from India. *Discover Education*, 4, 22. <https://doi.org/10.1007/s44217-025-00408-7>
- [26] Tommasi, M., Adrogué, C., Anauati, M. A., Sáenz Guillén, L., & Alzú, M. S. (2025). *El nivel socioeconómico no lo define todo: el rol de las escuelas en el rendimiento*. Observatorio de Argentinos por la Educación. Disponible en: https://argentinosporlaeducacion.org/wp-content/uploads/2025/04/El-nivel-socioeconomico-no-lo-define-todo_-el-rol-de-las-escuelas-en-el-rendimiento-1.pdf.
- [27] UNESCO. (2015). *TERCE: Factores asociados. Resumen ejecutivo*. OREALC/UNESCO Santiago. <https://unesdoc.unesco.org/>
- [28] Wang, X., Yao, J., & Zhou, S. (2022). Does housework help improve academic performance? Best Evidence in Chinese Education, 10(1), 1283–1301

- [29] Yang, Y., Maeda, Y., & Gentry, M. (2024). The relationship between mathematics self-efficacy and mathematics achievement: Multilevel analysis with NAEP 2019. *Large-scale Assessments in Education*, 12, 16. <https://doi.org/10.1186/s40536-024-00204-z>